금융 시계열 분석 · 설명자료

AR 모형의 계수 추정

네 가지 방법과 Yule-Walker

오늘 값을 어제·그제 값으로 설명하는 AR 모형 — 계수를 구하는 방법을 한눈에 정리한다.

방법 네 가지 | Yule-Walker | 수치 예제 | 정상성 가정

원자료: ritvikmath, The Yule-Walker Method (YouTube) | 비전공자·학부생용 |
2026. 9.

EXECUTIVE SUMMARY

한 장으로 보는 AR 계수 추정

방법 전체를 먼저 펼치고, 그중 Yule-Walker를 자세히 본다.

무엇을	AR(p) 모형의 계수 $\varphi_1 \dots \varphi_p$와 잡음 분산 σ^2를 데이터로 알아낸다
방법	① OLS ② Yule-Walker ③ Burg ④ 최대우도(MLE) — 네 가지가 표준이다
핵심	Yule-Walker는 자기상관만으로 연립방정식을 풀어 계수를 얻는다
주의	정상성이 전제다. 1에 가까운 시계열에서는 Yule-Walker가 가장 크게 빗나간다

방법은 넷, 데이터가 길고 정상이면 답은 거의 같습니다 — 차이는 경계에서 납니다

CONTENTS

다섯 단계와 부록으로 설명합니다

01
기본 개념
용어 · 자기상관 · AR(p) · 정상성

02
추정 방법 네 가지
OLS · Yule-Walker · Burg · MLE

03
Yule-Walker 자세히
유도 · 3단계 · 수치 예제 · 차수

04
방법 비교와 선택
같은 데이터 · 모의실험 · 선택 기준

05
활용과 주의
쓰이는 곳 · 정상성 · 코드 · 문제

부록
계산 속도
Big-O · 비용 비교 · 실측

01. 기본 개념

여덟 개의 용어로 이 자료를 모두 읽을 수 있다

처음 보는 기호는 이 표로 돌아와 확인한다.

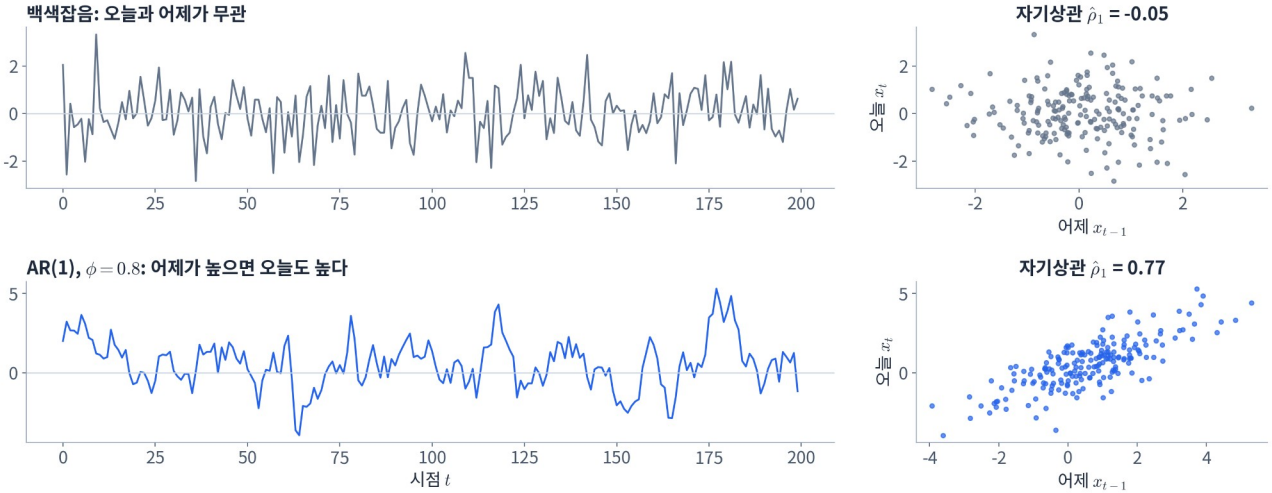
용어	쉬운 뜻	기호
시계열 · 시차	시간 순서로 기록한 값 · 몇 칸 떨어진 과거인가 (어제 = 시차 1)	x_t · k
백색잡음	평균 0, 서로 아무 관련 없는 순수한 무작위 충격	ε_t
자기공분산 · 자기상관	자기 자신의 과거와 같이 움직이는 정도 · 그것을 −1~1로 표준화	γ_k · $\rho_k = \gamma_k/\gamma_0$
정상성	시간이 흘러도 평균·분산·자기상관이 변하지 않는 성질	—
추정 (estimation)	데이터로 모르는 값(계수)을 알아내는 일. 추정값에는 ^(햇)을 붙인다	φ

Yule-Walker의 재료는 자기상관 하나뿐입니다

01. 기본 개념

자기상관은 어제가 오늘을 얼마나 닮았는지를 잰다

위: 백색잡음(무관) / 아래: AR(1), φ = 0.8. 오른쪽은 어제(x축)와 오늘(y축)의 산점도.



산점도가 기울수록 ρ_1이 크고, AR(1)에서는 이 ρ_1이 곧 계수 φ_1입니다

01. 기본 개념

AR(p)는 자기 과거값에 대한 선형회귀이다

추정 대상은 계수 $\varphi_1 \dots \varphi_p$와 잡음 분산 σ^2 두 가지다.

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + \varepsilon_t, \qquad \varepsilon_t \sim \mathrm{WN}(0, \sigma^2)$$

$$\mathrm{Cov}(X_t, X_{t-k}) = \gamma_k \quad (\text{depends on } k \text{ only, not on } t), \qquad \gamma_{-k} = \gamma_k$$

약정상성 (weak stationarity)

- 평균 일정, 분산 유한
- 공분산은 시차 k만의 함수 → γ_k 하나로 요약

비정상이면

- 공분산이 $\gamma_{t,k}$처럼 시점마다 다르다
- 표본 전체를 하나의 γ_k로 평균 낼 근거가 없다

Yule-Walker 방법 전체가 'γ_k는 t에 무관하다'는 한 줄에 기대고 있습니다

02. 추정 방법 네 가지

AR 계수를 구하는 표준 방법은 네 가지이다

무엇을 맞추느냐가 다를 뿐, 모두 같은 AR 모형의 계수를 구한다.

① OLS	② Yule-Walker	③ Burg	④ MLE
회귀로 푼다	**자기상관을 맞춘다**	**앞뒤로 예측한다**	**확률을 최대화한다**
오늘 값을 과거값에 회귀해 예측오차 제곱합을 최소화	표본 자기상관을 이론식에 넣고 연립방정식을 푼다	앞 방향과 뒤 방향 예측오차를 함께 최소화	관측 데이터가 나올 확률 (우도)이 가장 큰 계수
가장 익숙한 방법	이 자료의 주인공	신호처리 표준	통계 패키지 기본

네 방법을 먼저 훑어보고, 그중 Yule-Walker를 자세히 봅니다

02. 추정 방법 네 가지

AR(1)에서는 세 방법의 분자가 같고 분모만 다르다

$d_t = x_t - \bar{x}$ (평균에서 벗어난 정도). 분자는 모두 이웃한 편차의 곱이다.

$$\text{OLS}: \quad \hat{\phi} = \frac{\sum_{t=2}^{n} d_t\, d_{t-1}}{\sum_{t=2}^{n} d_{t-1}^2}$$

$$\text{YW}: \quad \hat{\phi} = \frac{\sum_{t=2}^{n} d_t\, d_{t-1}}{\sum_{t=1}^{n} d_t^2}$$

$$\text{Burg}: \quad \hat{\phi} = \frac{2\sum_{t=2}^{n} d_t\, d_{t-1}}{\sum_{t=2}^{n}\left(d_t^2 + d_{t-1}^2\right)}$$

분모를 읽는 법

- OLS: 마지막 값을 뺀 제곱합
- YW: 모든 값의 제곱합 → 가장 크다
- Burg: 앞뒤 두 제곱합의 평균
- MLE: 공식 없이 컴퓨터로 최적화
- → YW는 분모가 커서 작게 추정

④ MLE는 닫힌 공식이 없어 수치 최적화로 구한다.

분모가 가장 큰 YW는 늘 가장 조심스러운(0에 가까운) 추정을 냅니다

02. 방법 ① OLS

OLS는 AR 모형을 보통의 회귀식으로 보고 푼다

설명변수가 자기 과거값이라는 점만 다르다. 조건부 최소제곱(CLS)이라고도 한다.

$$\hat{\phi}^{\mathrm{OLS}} = \arg\min_{\phi} \sum_{t=p+1}^{n} \left(x_t - \phi_1 x_{t-1} - \cdots - \phi_p x_{t-p}\right)^2$$

$$\hat{\phi}_{\mathrm{OLS}} = (X^\top X)^{-1} X^\top y, \qquad X \in \mathbb{R}^{n \times p},\ y \in \mathbb{R}^n$$

장점

- 회귀분석을 알면 바로 쓸 수 있다
- 소표본 편향이 YW보다 작다
- 외부 변수를 함께 넣기 쉽다

약점

- 추정 모형이 비정상으로 나올 수 있다
- 처음 p개 관측치는 설명변수로만 쓴다
- 차수를 바꾸면 처음부터 다시 푼다

가장 익숙하지만, 추정 모형이 정상이라는 보장은 없습니다

02. 방법 ② Yule-Walker

Yule-Walker는 자기상관을 이론식에 맞춰 계수를 구한다

통계학 용어로는 적률법(method of moments)이다. 03장에서 자세히 본다.

$$\gamma_k = \phi_1\gamma_{k-1} + \phi_2\gamma_{k-2} + \cdots + \phi_p\gamma_{k-p}, \qquad k = 1, 2, \ldots, p$$

장점

- 자기상관만 있으면 된다
- 추정 모형이 항상 정상이다
- 차수를 하나씩 올리며 한 번에 푼다

약점

- 소표본에서 0 쪽으로 치우친다
- 1에 가까운 계수에서 가장 크게 빗나간다
- 정상성이 깨지면 조용히 틀린다

단순하고 안정적 — 대신 경계 근처에서 가장 보수적으로 추정합니다

02. 방법 ③ Burg

Burg는 앞으로도, 뒤로도 예측해 오차를 함께 줄인다

정상 시계열은 시간을 거꾸로 뒤집어도 성질이 같다. 이 대칭을 활용한다.

$$\min_{\phi} \sum_{t=2}^{n} \Big[\underbrace{(d_t - \phi\, d_{t-1})^2}_{\text{forward error}} + \underbrace{(d_{t-1} - \phi\, d_t)^2}_{\text{backward error}} \Big]$$

장점

- 추정 모형이 항상 정상이다
- 소표본에서도 치우침이 작다
- 짧은 신호에 강해 신호처리 표준

약점

- 개념이 낯설다
- 경제·금융 패키지 기본값은 아니다
- 주파수 분석에서 가끔 가짜 봉우리

YW의 안정성과 OLS의 정확성을 함께 노린 방법입니다

02. 방법 ④ MLE

MLE는 관측 데이터가 나올 확률이 가장 큰 계수를 고른다

잡음이 정규분포를 따른다고 가정한다. 평균 μ도 함께 추정한다.

$$\log L(\phi, \mu, \sigma^2) = -\tfrac{n}{2}\log(2\pi\sigma^2) - \tfrac{1}{2\sigma^2}\sum_{t=2}^{n}\big(x_t - \mu - \phi(x_{t-1} - \mu)\big)^2 + (\text{first-obs. term})$$

$$\hat{\phi}^{\text{MLE}} = \arg\max_{\phi,\mu,\sigma^2} \log L(\phi, \mu, \sigma^2 \mid x_1, \ldots, x_n)$$

장점

- 통계적으로 가장 효율적이다
- 표준오차·AIC·BIC가 함께 나온다
- ARMA·ARIMA로 그대로 확장된다

약점

- 공식이 없어 반복 계산이 필요하다
- 분포 가정이 틀리면 흔들린다
- 초기값으로 YW 결과를 쓰는 일이 많다

statsmodels ARIMA 등 통계 패키지의 기본 방법입니다

03. Yule-Walker 자세히

양변에 과거값을 곱하고 공분산을 취하면 계수식이 나온다

공분산의 선형성으로 상수 φ를 꺼내고 합을 나눈다. AR(2), k ≥ 1.

$$\gamma_k = \mathrm{Cov}(X_t, X_{t-k}) = \phi_1 \underbrace{\mathrm{Cov}(X_{t-1}, X_{t-k})}_{\gamma_{k-1}} + \phi_2 \underbrace{\mathrm{Cov}(X_{t-2}, X_{t-k})}_{\gamma_{k-2}} + \underbrace{\mathrm{Cov}(\varepsilon_t, X_{t-k})}_{0\ (k \geq 1)}$$

$$\gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2} + \cdots + \phi_p \gamma_{k-p}, \qquad k = 1, 2, \ldots, p$$

정상성이 쓰이는 곳

$\mathrm{Cov}(X_{t-1}, X_{t-k}) = \gamma_{k-1}$로 줄이는 단계

잡음 항이 사라지는 이유

ε_t는 과거값 X_{t-k}($k \geq 1$)와 무상관

k = 1, …, p의 p개 식이 미지수 p개($\varphi_1 \ldots \varphi_p$)를 정확히 결정합니다

03. Yule-Walker 자세히

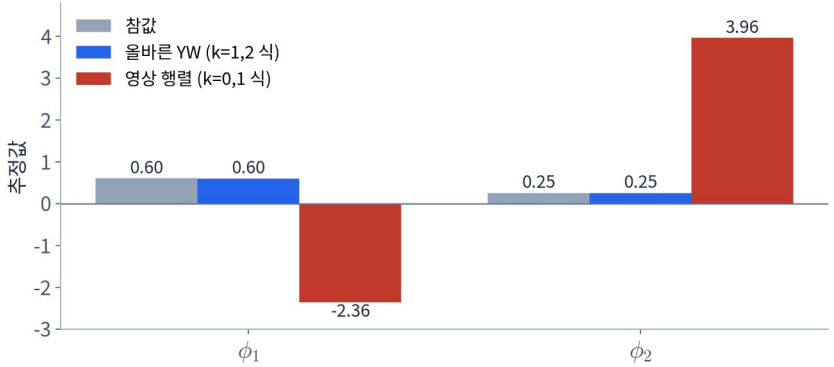
k = 0 식은 계수가 아니라 잡음 분산 σ²를 준다

영상은 Cov(εₜ, Xₜ)를 0으로 지워 k = 0, 1 식으로 φ를 풀었다.

$$\gamma_0 = \phi_1\gamma_1 + \phi_2\gamma_2 + \sigma^2 \qquad (\mathrm{Cov}(\varepsilon_t, X_t) = \sigma^2 \neq 0)$$

$$\begin{pmatrix}\gamma_0\\ \gamma_1\end{pmatrix} = \begin{pmatrix}\gamma_1 & \gamma_2\\ \gamma_0 & \gamma_1\end{pmatrix}\begin{pmatrix}\phi_1\\ \phi_2\end{pmatrix}$$

영상의 계 (틀림)



참값 (0.60, 0.25)인 AR(2), n = 5,000

영상의 계 → (−2.36, 3.96)

계수는 k = 1…p 식으로 풀고, k = 0 식은 σ² = γ₀ − φᵀγ 계산에 씁니다

03. Yule-Walker 자세히

Yule-Walker 방정식은 행렬식 하나로 정리된다

좌: AR(2) / 우: 일반 AR(p). 표본값을 넣으면 곧 추정량이다.

$$\begin{pmatrix} \gamma_0 & \gamma_1 \\ \gamma_1 & \gamma_0 \end{pmatrix} \begin{pmatrix} \phi_1 \\ \phi_2 \end{pmatrix} = \begin{pmatrix} \gamma_1 \\ \gamma_2 \end{pmatrix}$$

AR(2)

$$\underbrace{\begin{pmatrix} \gamma_0 & \gamma_1 & \cdots & \gamma_{p-1} \\ \gamma_1 & \gamma_0 & \cdots & \gamma_{p-2} \\ \vdots & \vdots & \ddots & \vdots \\ \gamma_{p-1} & \gamma_{p-2} & \cdots & \gamma_0 \end{pmatrix}}_{\Gamma_p} \begin{pmatrix} \phi_1 \\ \phi_2 \\ \vdots \\ \phi_p \end{pmatrix} = \underbrace{\begin{pmatrix} \gamma_1 \\ \gamma_2 \\ \vdots \\ \gamma_p \end{pmatrix}}_{\boldsymbol{\gamma}_p}$$

$$\hat{\gamma}_k = \frac{1}{n}\sum_{t=k+1}^{n}(x_t - \bar{x})(x_{t-k} - \bar{x}), \qquad k = 0, 1, \ldots, p$$

$$\hat{\boldsymbol{\phi}} = \hat{\Gamma}_p^{-1}\hat{\boldsymbol{\gamma}}_p, \qquad \hat{\sigma}^2 = \hat{\gamma}_0 - \hat{\boldsymbol{\phi}}^{\top}\hat{\boldsymbol{\gamma}}_p$$

분모를 n으로 두면 행렬이 항상 잘 풀리고(양정치), 추정 모형은 늘 정상입니다

03. Yule-Walker 자세히

분산으로 나누면 자기상관만으로 된 방정식이 된다

교과서에서 더 자주 보는 모양이다. 계수는 똑같이 나온다.

$$\underbrace{\begin{pmatrix} 1 & \rho_1 & \cdots & \rho_{p-1} \\ \rho_1 & 1 & \cdots & \rho_{p-2} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p-1} & \rho_{p-2} & \cdots & 1 \end{pmatrix}}_{R} \begin{pmatrix} \phi_1 \\ \vdots \\ \phi_p \end{pmatrix} = \underbrace{\begin{pmatrix} \rho_1 \\ \vdots \\ \rho_p \end{pmatrix}}_{r}$$

추정 3단계

- 1단계: 데이터로 $\rho_1 \dots \rho_p$ 계산
- 2단계: $R\varphi = r$ 풀기 → φ
- 3단계: $\sigma^2 = \gamma_0(1 - \Sigma \varphi_i \rho_i)$

$$\rho_k = \frac{\gamma_k}{\gamma_0} \in [-1, 1], \qquad \rho_0 = 1$$

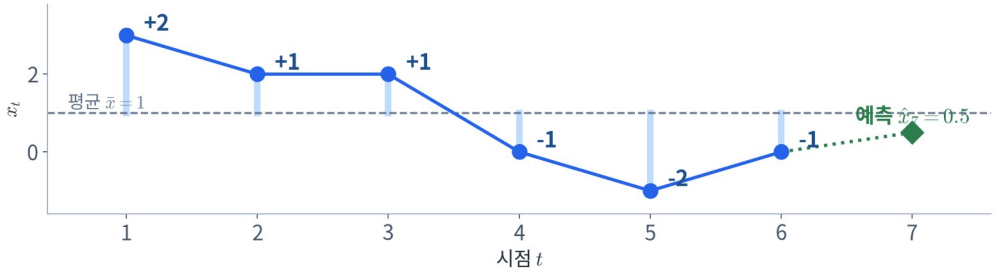
$$\mathrm{AR}(1): \quad \hat{\phi}_1 = \hat{\rho}_1, \qquad \hat{\sigma}^2 = \hat{\gamma}_0\left(1 - \hat{\phi}_1^2\right)$$

AR(1)이면 행렬도 필요 없습니다 — 어제와 오늘의 자기상관이 곧 계수입니다

03. Yule-Walker 자세히

관측치 6개로 AR(1) 계수를 끝까지 구해 본다

데이터 x = (3, 2, 2, 0, −1, 0). 먼저 평균 1을 빼 편차 d_t를 만든다.



t	1	2	3	4	5	6	합
$d_t = x_t - 1$	+2	+1	+1	−1	−2	−1	0
d_t^2	4	1	1	1	4	1	12
$d_t \cdot d_{t-1}$	—	2	1	−1	2	2	6

필요한 숫자는 두 개뿐 — 편차 제곱의 합 12와 이웃한 편차 곱의 합 6입니다

03. Yule-Walker 자세히

자기상관 0.5가 곧 계수이고, 다음 값 예측은 0.5이다

두 합을 n = 6으로 나누면 자기공분산이 된다. 예측은 평균을 뺀 모형으로 한다.

$$\hat{\gamma}_0 = \tfrac{1}{6}(4+1+1+1+4+1) = \tfrac{12}{6} = 2 \qquad \hat{\gamma}_1 = \tfrac{1}{6}(2+1-1+2+2) = \tfrac{6}{6} = 1$$

$$\hat{\rho}_1 = \tfrac{\hat{\gamma}_1}{\hat{\gamma}_0} = 0.5 \;\Rightarrow\; \hat{\phi}_1 = 0.5, \qquad \hat{\sigma}^2 = 2\,(1 - 0.5^2) = 1.5$$

$$\hat{x}_7 = \bar{x} + \hat{\phi}_1(x_6 - \bar{x}) = 1 + 0.5\,(0 - 1) = 0.5$$

해석

- 평균 이탈이 다음 기에 절반만 남는다
- 분산 2 중 25%는 어제로, 75%는 새 충격

같은 데이터, 다른 방법

- OLS 0.545 · Burg 0.632 · MLE 0.662
- 차이의 이유는 04장에서 본다

AR(1)의 Yule-Walker 추정 = '이웃한 편차 곱의 합 ÷ 편차 제곱의 합'입니다

03. Yule-Walker 자세히

자기상관 0.80과 0.55에서 계수 1.00과 −0.25를 얻는다

AR(2) 손계산 예제. 2×2 연립방정식은 공식으로 바로 풀린다.

$$\begin{pmatrix} 1 & 0.8 \\ 0.8 & 1 \end{pmatrix} \begin{pmatrix} \phi_1 \\ \phi_2 \end{pmatrix} = \begin{pmatrix} 0.80 \\ 0.55 \end{pmatrix}$$

$$\hat{\phi}_1 = \frac{\rho_1(1-\rho_2)}{1-\rho_1^2} = \frac{0.8\times 0.45}{0.36} = 1.00$$

$$\hat{\phi}_2 = \frac{\rho_2-\rho_1^2}{1-\rho_1^2} = \frac{0.55-0.64}{0.36} = -0.25$$

$$\hat{\sigma}^2 = \hat{\gamma}_0(1 - 1.00 \times 0.80 + 0.25 \times 0.55) = 0.3375\,\hat{\gamma}_0$$

계수 해석

- 어제 값의 영향이 크다 (φ_1 = 1.00)
- 그제 값은 살짝 되돌린다 (φ_2 = −0.25)

설명력

- 충격 몫 34%, 과거값으로 66% 설명
- 근이 2 > 1 → 전체 모형은 정상

φ_1 = 1이어도 AR(2) 전체로는 정상 — 계수 하나가 아니라 조합을 봅니다

03. Yule-Walker 자세히

자기공분산 행렬은 대칭 토플리츠 행렬이다

(i, j) 원소가 $\gamma_{|i-j|}$ — p^2개 원소가 실제로는 p개 값으로 정해진다.

Γ_5: AR(5)의 자기공분산 행렬

γ_0	γ_1	γ_2	γ_3	γ_4
γ_1	γ_0	γ_1	γ_2	γ_3
γ_2	γ_1	γ_0	γ_1	γ_2
γ_3	γ_2	γ_1	γ_0	γ_1
γ_4	γ_3	γ_2	γ_1	γ_0

대각선마다 같은 값 = 토플리츠, 게다가 대칭

토플리츠 · 비대칭

a	b	c
d	a	b
e	d	a

$b \neq d$여도 토플리츠

대칭 · 비(非)토플리츠

1	2	3
2	4	5
3	5	6

대각선 값 1, 4, 6이 다름

대각선마다 같은 값 — 이 규칙성 덕에 차수를 하나씩 올리며 풀 수 있습니다

03. Yule-Walker 자세히

레빈슨-더빈은 AR(1)부터 한 계단씩 올라가며 푼다

AR(1)을 풀고, 그 답을 고쳐 AR(2), 다시 AR(3)... 역행렬 없이 푼다. $v_0 = \gamma_0$.

$$\phi_{kk} = \frac{\gamma_k - \sum_{j=1}^{k-1} \phi_{k-1,j}\,\gamma_{k-j}}{v_{k-1}}, \qquad v_0 = \gamma_0$$

$$\phi_{kj} = \phi_{k-1,j} - \phi_{kk}\,\phi_{k-1,k-j} \quad (j < k), \qquad v_k = v_{k-1}(1 - \phi_{kk}^2)$$

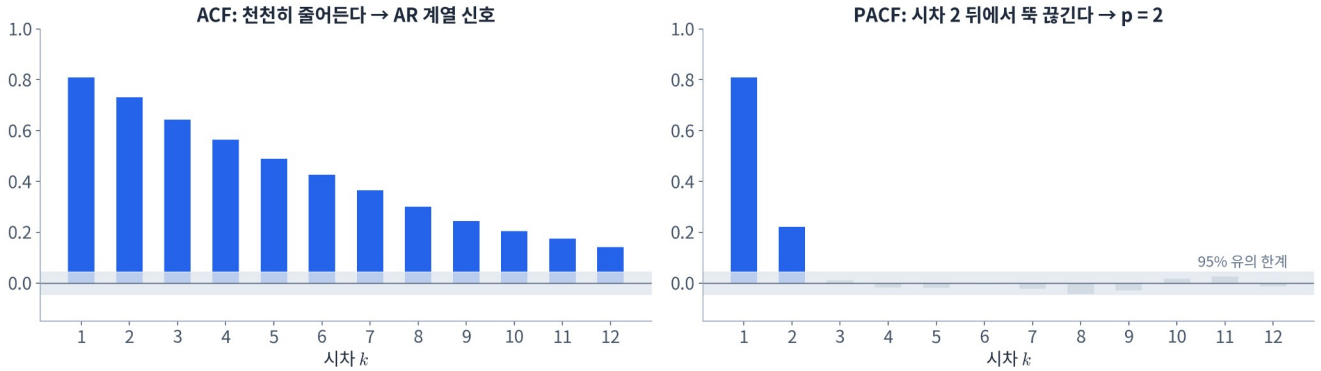
φ_{kk}	v_k	$\lvert\varphi_{kk}\rvert < 1$
편자기상관(PACF)	**예측오차 분산**	**정상성 보장**
차수 선택용 PACF가 그대로 나온다	차수 k 모형의 잡음 분산. $v_p = \sigma^2$	1 미만이 유지되어 모형이 늘 정상

레빈슨-더빈은 계수·PACF·σ^2를 한 번에 주는 재귀입니다

03. Yule-Walker 자세히

차수 p는 PACF가 끊기는 곳에서 정한다

참값 AR(2) 데이터 2,000개. 회색 띠는 95% 유의 한계다.



보조 수단: p = 1, 2, …로 추정해 AIC·BIC가 가장 작은 p를 고른다. 레빈슨-더빈이 모든 차수의 오차분산 v_k를 한 번에 주므로 비교가 쉽다.

ACF는 천천히 줄고, PACF는 시차 p 뒤에서 끊깁니다 — 이것이 AR(p)의 지문입니다

04. 방법 비교와 선택

같은 6개 관측치에 네 방법을 쓰면 0.50~0.66이 나온다

앞의 AR(1) 예제 x = (3, 2, 2, 0, −1, 0). 이웃한 편차 곱의 합은 6이다.

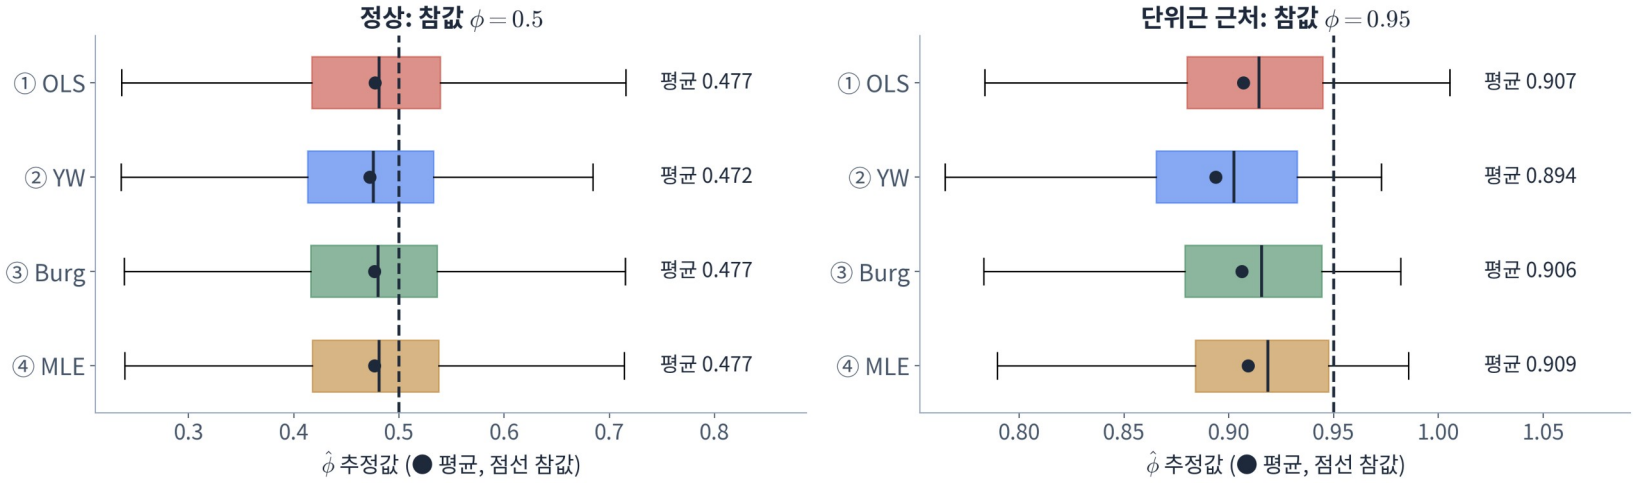
방법	계산	추정값 φ_1	특징
① OLS	6 / (12 − 1) = 6 / 11	0.545	마지막 편차는 분모에서 빠진다
② Yule-Walker	6 / 12	0.500	분모가 가장 커서 가장 작다
③ Burg	(2 × 6) / (8 + 11) = 12 / 19	0.632	앞뒤 두 제곱합의 평균을 분모로
④ MLE	수치 최적화 (평균도 함께 추정: 1.20)	0.662	평균을 따로 추정해 값이 다르다

관측치 6개처럼 적으면 방법마다 답이 크게 갈립니다

04. 방법 비교와 선택

정상 구간에서는 네 방법이 같고, 경계에서는 YW만 처진다

AR(1), 관측치 100개, 반복 500회 모의실험. 상자는 추정값의 가운데 50%.



참값 0.95에서 YW 0.894, 나머지 셋은 0.906~0.909 — MLE가 가장 가깝습니다

04. 방법 비교와 선택

상황에 따라 방법을 고른다

한 가지 정답은 없다. 데이터 길이, 정상성, 필요한 출력이 기준이다.

상황	권장 방법	이유
데이터가 길고 확실히 정상	아무 방법이나 (YW 포함)	네 방법이 거의 같은 답
짧은 자료 · 계수가 1에 가까움	Burg 또는 MLE	YW의 치우침이 가장 크다
표준오차·AIC 등 추론이 필요	MLE	통계량이 함께 나온다
외부 변수를 함께 넣는 회귀	OLS	회귀식 확장이 자연스럽다
PACF 계산 · MLE 초기값	Yule-Walker	차수별 결과를 한 번에 준다

실무 기본값은 MLE, 빠른 탐색과 PACF는 Yule-Walker입니다

05. 활용과 주의

Yule-Walker는 신호 처리와 시계열 분석 곳곳에 쓰인다

추정 모형이 항상 정상이고 계산이 단순하다는 점이 선택 이유다.

음성 신호	스펙트럼 추정	경제·금융	분석 도구
선형예측부호화(LPC)	**주파수 성분 분석**	**물가·금리·수익률 예측**	**PACF · 차수 선택**
휴대전화 음성 코덱이 짧은 구간마다 AR 계수를 다시 구한다	AR 계수로 신호의 주파수 분포를 매끄럽게 추정	추정 모형이 늘 정상이라 장기 예측이 발산하지 않는다	ARIMA 초기값, PACF 그래프 계산의 내부 엔진
실시간 처리	짧은 자료에 강함	안정성	레빈슨-더빈

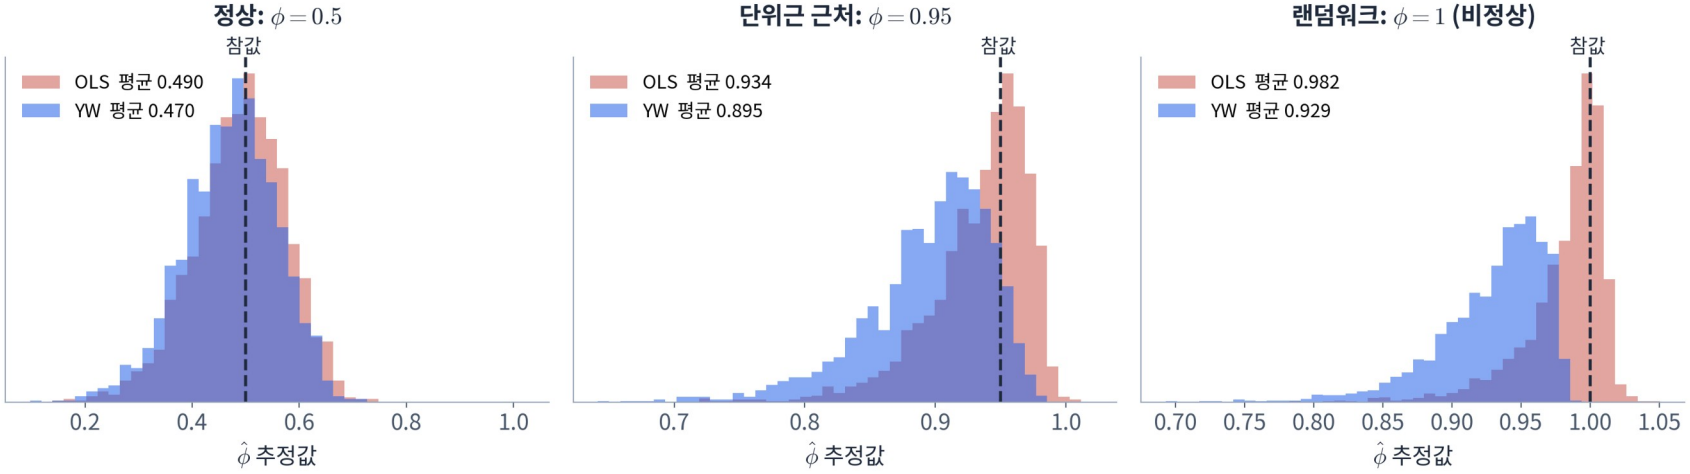
MP3는 LPC가 아니라 변환(MDCT) 코덱입니다 — 인터넷의 흔한 오해

변동성 모델링은 보통 GARCH의 영역이며, YW는 보조 용도에 그친다.

05. 활용과 주의

단위근에 가까울수록 YW는 참값보다 작게 나온다

AR(1), n = 100, 반복 2,000회. 파랑: YW, 빨강: OLS.



랜덤워크를 넣어도 YW는 φ < 1을 돌려줍니다 — 경고 없이 조용히 틀립니다

05. 활용과 주의

네 방법 모두 statsmodels 한 줄로 쓸 수 있다

yule_walker의 기본값은 method="adjusted"(분모 n−k)이므로 "mle"를 지정한다.

```
from statsmodels.regression.linear_model import yule_walker, burg
from statsmodels.tsa.ar_model import AutoReg
from statsmodels.tsa.arima.model import ARIMA

phi_ols   = AutoReg(x, lags=p).fit().params          # ① OLS
phi_yw, _ = yule_walker(x, order=p, method="mle")   # ② Yule-Walker
phi_bg, _ = burg(x, order=p)                         # ③ Burg
phi_ml    = ARIMA(x, order=(p, 0, 0)).fit().params   # ④ MLE
```

검증: AR(2) 참값 (0.60, 0.25), n = 5,000 → YW (0.596, 0.253), OLS (0.596, 0.253). 데이터가 길면 같은 답이다.

실무에서는 네 결과를 나란히 놓고 크게 다르면 원인을 찾습니다

05. 활용과 주의

네 문제로 핵심을 확인한다

답은 오른쪽 굵은 글씨. 수업에서는 가리고 먼저 풀어 본다.

1	**AR(1), $\rho_1=0.6$, $\gamma_0=2$**	φ_1과 σ^2는? → $\varphi_1 = 0.6$, $\sigma^2 = 2(1 - 0.36) = 1.28$
2	**정상성은 어디서?**	$\mathrm{Cov}(X_{t-1}, X_{t-k})$를 γ_{k-1}로 바꾸는 단계
3	**k=0 식을 안 쓰는 이유**	$\mathrm{Cov}(\varepsilon_t, X_t) = \sigma^2$라는 미지수가 하나 더 들어 있다
4	**짧고 1에 가까운 자료**	YW보다 Burg·MLE — YW는 분모가 커 0 쪽으로 치우친다

방법은 넷, YW의 재료는 자기상관, 조건은 정상성 — 이렇게 기억합니다

정리

AR 계수는 네 가지 방법으로 구하고, Yule-Walker는 그중 가장 단순하다

① OLS · ② Yule-Walker · ③ Burg · ④ MLE — 정상이고 데이터가 길면 같은 답
짧거나 1에 가까우면 Burg·MLE, 정상성 확인이 언제나 먼저다.

원자료: ritvikmath, The Yule-Walker Method

A

부록

계산 속도 — OLS와 Yule-Walker

관심 있는 수강생을 위한 보충. 본문 이해에는 필요 없다.

부록. 계산 속도

Big-O는 데이터가 커질 때 계산이 늘어나는 속도를 뜻한다

상수는 무시하고 증가 속도만 본다. n: 관측치 수, p: 차수.

2배 → 2배

$O(n)$

자기공분산 한 개 계산

2배 → 4배

$O(p^2)$

Yule-Walker의 방정식 풀이

2배 → 8배

$O(p^3)$

OLS의 일반 역행렬

왜 중요한가

고빈도 금융 데이터(n 수십만)나 음성 신호(짧은 구간마다 반복 추정)에서는 증가 속도의 차이가 실제 대기 시간이 된다.

같은 답이면 증가 속도가 느린 쪽이 유리합니다 — 영상이 강조한 YW의 장점입니다

부록. 계산 속도

OLS 닫힌 해의 계산 비용은 $O(np^2 + p^3)$이다

n: 관측치 수, p: 차수(=특성 수). n ≫ p를 가정한다.

$$\hat{\phi}_{\text{OLS}} = (X^\top X)^{-1} X^\top y, \qquad X \in \mathbb{R}^{n \times p},\ y \in \mathbb{R}^n$$

단계	연산	복잡도
$X^\top X$	(p×n)(n×p) — 원소 p^2개 × 곱셈 n번	$O(np^2)$
역행렬	일반 p×p 행렬	$O(p^3)$
$X^\top y$, 곱	(p×n)(n×1), (p×p)(p×1)	$O(np) + O(p^2)$
합계	지배항만 남김	$O(np^2 + p^3)$

영상은 $X^\top X$를 $O(n^2p)$로 적었으나 $O(np^2)$가 맞습니다 — 결론(YW가 싸다)은 같습니다

부록. 계산 속도

Yule-Walker 파이프라인은 네 단계로 끝난다

자기공분산 계산이 O(np), 선형계 풀이가 $O(p^2)$다.

0단계 관문 — 정상성 확인 (ADF·KPSS 검정, 차분) · 통과하지 못하면 아래 파이프라인은 편향된 값을 낸다

① 데이터	② 자기공분산	③ 토플리츠 풀이	④ 산출
시계열 n개 관측치 평균을 뺀다	$\gamma(0), \gamma(1), \cdots, \gamma(p)$ p+1개 × 각 O(n) O(np)	$\Gamma \cdot \phi = \gamma$ (p×p) 레빈슨-더빈 재귀 $O(p^2)$	$\phi(1), \cdots, \phi(p), \sigma^2$ + PACF $\phi(k,k)$ (덤) 항상 정상 모형

합계 $O(np + p^2)$ · OLS는 $O(np^2 + p^3)$ — 차이는 p가 클수록 벌어진다

부록. 계산 속도

YW는 두 단계 모두에서 한 차수씩 가볍다

n ≫ p일 때 지배항 기준. 자기공분산은 FFT로 O(n log n)도 가능하다.

$$\text{OLS}: \; O(np^2) + O(p^3) \qquad \text{vs.} \qquad \text{Yule–Walker}: \; O(np) + O(p^2)$$

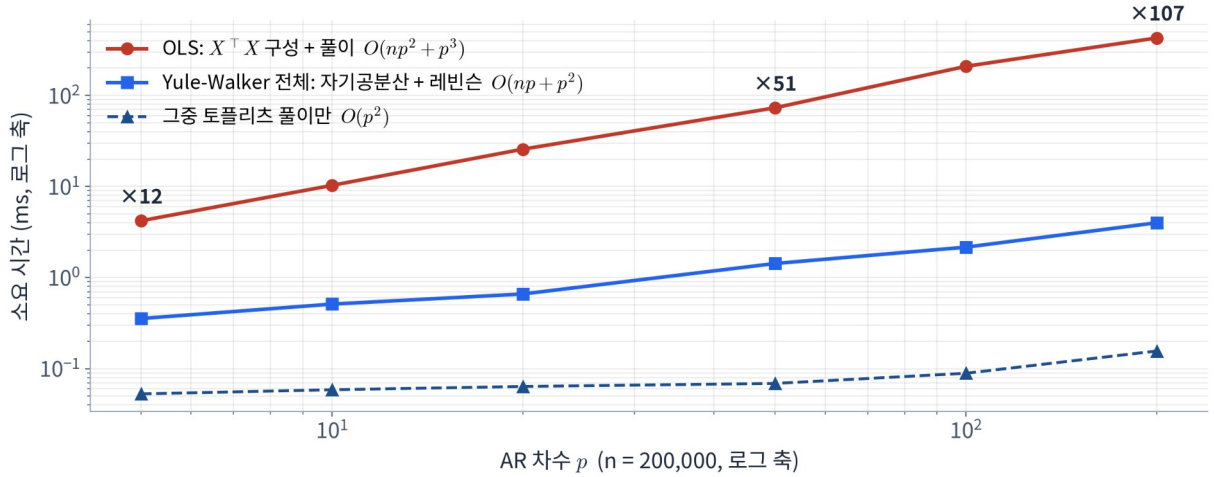
방법	자료 처리	선형계 풀이	합계
OLS	$X^\top X$: $O(np^2)$	일반 역행렬: $O(p^3)$	$O(np^2 + p^3)$
Yule-Walker	$\gamma_0 \ldots \gamma_p$: $O(np)$	레빈슨-더빈: $O(p^2)$	$O(np + p^2)$
차이의 원천	특성 간 교차곱 → 시차별 1회	토플리츠 구조 활용	p배 · p배

p가 클수록(고차 AR, 스펙트럼 추정, LPC) 차이가 실제 시간으로 드러납니다

부록. 계산 속도

n=200,000에서 YW가 OLS보다 12~107배 빨랐다

numpy · scipy solve_toeplitz, 3회 중 최솟값. 절대 시간은 기기에 따라 다르다.



선형계 풀이만 떼어 보면 p = 200에서도 0.16ms — 비용은 거의 자기공분산 계산입니다