베이지안 시계열 입문 · 사례 강의 후속편

선거 예측의 베이지안 확장

사전분포 · 상태공간 · 계층 모형 · 상관 오차

2024 대선 사례에서 드러난 한계를 다섯 가지 베이지안 도구로 고치고, 같은 데이터로 원 모형과 비교한다

사전분포 교정 | 칼만 필터 | 하우스 효과 수축 | Brier 0.29→0.12

참고: Linzer (2013) · Heidemanns·Gelman·Morris (2020) · Shirani-Mehr et al. (2018) | 2026. 9.

EXECUTIVE SUMMARY

한 장으로 보는 개선 방향

원 모형의 네 가지 약점에 각각 대응하는 베이지안 도구를 붙인다.

사전분포	2020 마진을 그대로 쓰지 않고 주 성향(state lean) + 펀더멘털 전국 환경으로 분해한다
시간	여론조사 신뢰도 w를 손으로 정하지 않고 상태공간 모형의 칼만 이득으로 추정한다
여론조사	조사기관별 하우스 효과와 공통 편향을 계층 모형으로 추정하고 수축한다
오차 구조	전국·권역·주 요인으로 공분산을 만들고, 과거 선거로 백테스트해 채점한다

같은 2024 데이터로 돌리면 주별 Brier 점수가 0.288에서 0.120으로 개선된다

CONTENTS

다섯 개의 도구로 설명한다

01
사전분포 교정
주 성향 + 펀더멘털 전국 환경

02
동적 상태공간
랜덤워크 · 칼만 필터 · 자동 가중치

03
여론조사 관측 모형
하우스 효과 수축 · 공통 편향

04
요인 상관 구조
전국·권역·주 공분산 · 결과 비교

05
검증과 운영
채점 규칙 · 백테스트 · 금융 연결

※
자료 기준
실제 여론조사 + 합성 예시

STARTING POINT

원 모형의 약점은 네 곳에 있다

앞 사례 강의(270 : 268 예측)에서 진단한 내용을 개선 과제로 옮긴다.

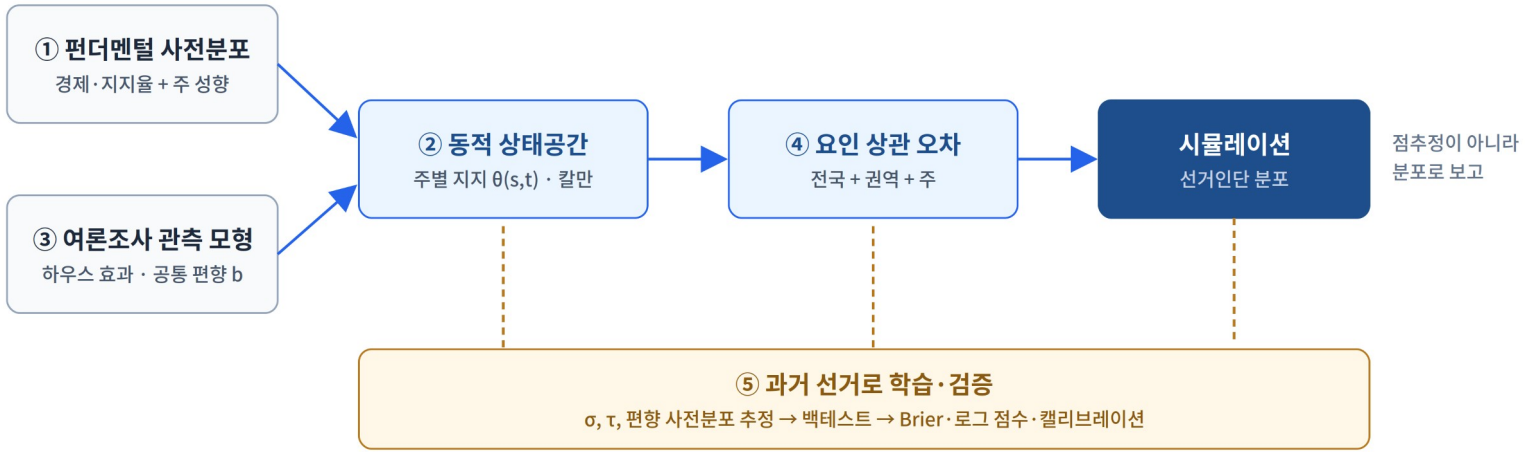
약점	원 모형	개선 도구	장
사전분포	2020 마진 그대로 (전국 D+4.5 내장)	주 성향 + 펀더멘털 전국 환경	01
가중치 w	주관적 분포로 수동 설정	상태공간 · 칼만 이득으로 추정	02
여론조사 오차	표본오차만 암묵적으로 반영	하우스 효과 · 공통 편향 계층 모형	03
주 간 상관	주별 독립 ±1%	전국·권역·주 요인 공분산	04

하나씩 고치되, 모든 설정값은 과거 선거로 학습·검증한다 (05장)

STARTING POINT

개선 모형은 다섯 블록으로 조립된다

Linzer(2013)와 Economist 모형(Heidemanns·Gelman·Morris, 2020)의 공통 골격.



원 모형의 손잡이 두 개(w, σ)가 모두 데이터로 추정되는 모수로 바뀐다

01

사전분포

사전분포 교정

지난 선거 결과를 '주 성향'과 '전국 환경'으로 분해한다

01. 사전분포 교정

펀더멘털 모형은 여론조사 없이 전국 환경을 예측한다

Fundamentals model: 경제 성장률, 대통령 지지율, 현직 여부 등 구조 변수로 전국 득표를 회귀한다.

$$\hat{m}_{\text{nat}} = \beta_0 + \beta_1 \,\text{GDP} + \beta_2 \,\text{Approval} + \beta_3 \,\text{Incumbent}$$

경제	지지율	현직 여부
2분기 GDP 성장률 실질 가처분소득	현직 대통령 순지지율 (approve − disapprove)	집권당 재임 기간 'Time for Change' (Abramowitz)

선거 수개월 전에는 여론조사보다 펀더멘털이 더 정확하다는 것이 정치학의 경험 법칙

01. 사전분포 교정

주의 사전분포는 성향과 전국 환경의 합으로 쓴다

State lean: 그 주가 전국 평균보다 얼마나 민주당 쪽인가. 선거마다 비교적 안정적이다.

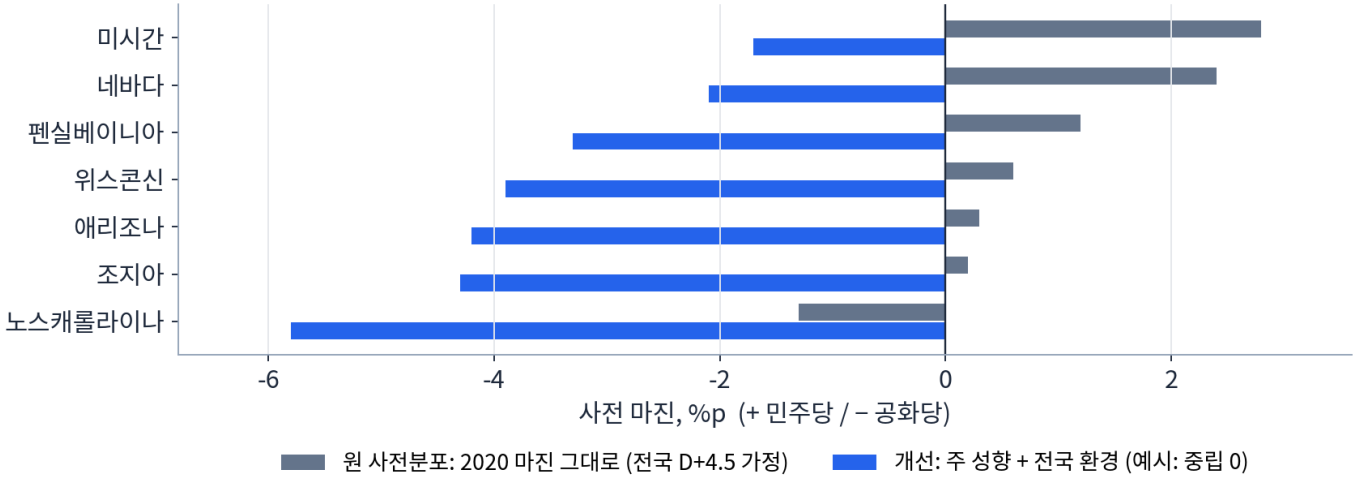
$$\text{prior}_s = \underbrace{\left(m_s^{2020} - m_{\text{nat}}^{2020}\right)}_{\text{state lean}} + \underbrace{\hat{m}_{\text{nat}}^{2024}}_{\text{fundamentals}}$$

원 사전분포	성향 분해
✗ 2020 마진 그대로 → 2020년 전국 환경 (D+4.5)까지 복사	▶ ✓ 성향은 2020에서, 전국 환경은 2024 펀더멘털에서
✗ 4년간 전국 분위기 변화가 사전분포에 반영되지 않는다	▶ ✓ 전국 분위기가 바뀌면 모든 주의 사전분포가 함께 이동

01. 사전분포 교정

전국 환경을 중립으로만 바꿔도 7곳 모두 공화당 쪽이 된다

파란 막대: 2020 성향 + 전국 환경 0 (예시). 실제 2024 전국 득표는 트럼프 약 +1.5%p.



원 모형의 해리스 쪽 편향은 대부분 '2020년 전국 환경을 그대로 복사한 것'에서 나왔다

02

시계열

동적 상태공간 모형

여론조사 신뢰도 w를 손으로 정하지 않고 데이터가 정하게 한다

02. 동적 상태공간 모형

진짜 지지율은 숨은 상태이고 여론조사는 그 잡음 섞인 관측이다

State-space model: 상태 방정식(랜덤워크) + 관측 방정식. Linzer(2013)의 동적 베이지안 모형이 이 구조다.

$$\theta_t = \theta_{t-1} + \omega_t, \quad \omega_t \sim N(0, q) \qquad y_t = \theta_t + v_t, \quad v_t \sim N(0, r)$$

$$K_t = \frac{P_{t|t-1}}{P_{t|t-1} + r}, \qquad \hat{\theta}_{t|t} = \hat{\theta}_{t|t-1} + K_t \left(y_t - \hat{\theta}_{t|t-1}\right)$$

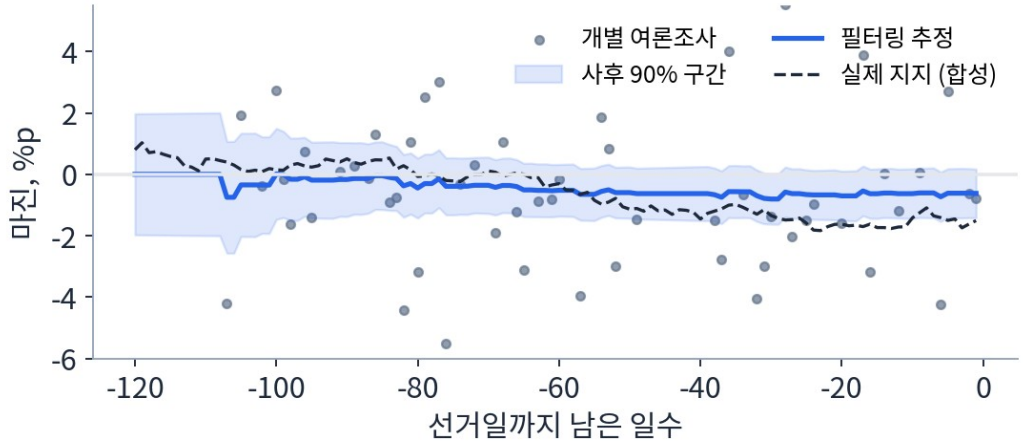
- **q (상태 잡음)** 지지율이 하루에 얼마나 움직이나 — 과거 선거에서 추정
- **r (관측 잡음)** 여론조사 한 건의 오차 — 표본 크기와 하우스 효과로 결정

02. 동적 상태공간 모형

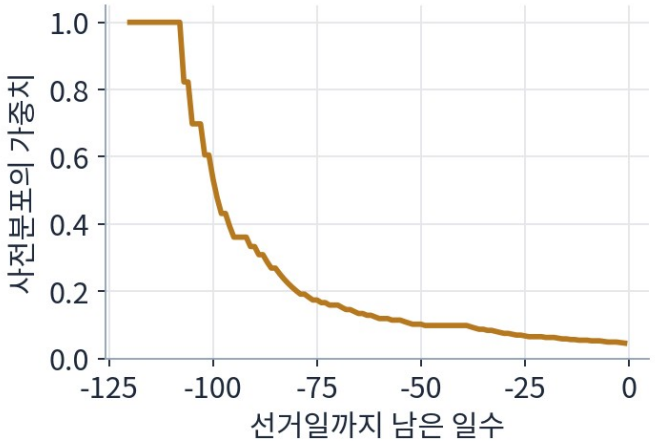
칼만 이득이 곧 여론조사 신뢰도 w다

합성 예시: 선거 120일 전부터 여론조사 55건. 사전분포 N(0, 1.2²), 조사당 오차 약 2.6%p.

① 칼만 필터: 여론조사가 쌓이며 구간이 좁아진다



② 사전분포 비중은 자동으로 줄어든다



초기에는 펀더멘털 사전분포가, 선거 직전에는 여론조사가 자동으로 주도한다 (선거일 사전 비중 5%)

02. 동적 상태공간 모형

가중치를 추정하면 주관적 설정 논쟁이 사라진다

원 모형의 w 분포(중심 0.7)와 상태공간 모형의 칼만 이득을 비교한다.

원 모형: w를 사람이 정함

- 0.4~0.95 주관적 분포, 중심 0.7
- 선거 4개월 전과 하루 전에 같은 w
- w를 바꾸면 승자가 바뀌는데 근거가 없다

상태공간: w가 추정됨

- K = P / (P + r): 불확실성 비율로 결정
- 여론조사가 쌓일수록 자동으로 커진다
- 조사 품질(r)이 나쁘면 자동으로 작아진다

베이지안 시계열의 핵심 — 결합 비율은 설정이 아니라 두 불확실성의 비율이다

03

여론조사

여론조사 관측 모형

표본오차 밖의 오차를 모형 안으로 들여온다

03. 여론조사 관측 모형

여론조사의 실제 오차는 보고된 오차의 약 두 배다

Shirani-Mehr, Rothschild, Goel & Gelman (2018, JASA): 주 단위 선거 여론조사 4,221건 분석.

표본오차	하우스 효과	공통 편향
보고되는 ±3%p	**조사기관별 치우침**	**모든 조사가 같이**
무작위 추출에서 오는 오차. 표본을 늘리면 줄어든다	가중 방식·투표 의향 판정·조사 방식의 차이	무응답 편향 등 업계 전체가 같은 방향으로 빗나감
sampling error	house effect	industry-wide bias

원 모형은 첫 번째만 암묵적으로 반영했다 — 두 번째와 세 번째가 2016·2020·2024를 모두 빗나가게 했다

03. 여론조사 관측 모형

여론조사 한 건은 네 가지 성분의 합으로 모형화한다

i = 조사 건, j = 조사기관, s = 주, t = 날짜. 하우스 효과와 공통 편향이 각각 사전분포를 가진다.

$$y_i = \theta_{s[i],t[i]} + h_{j[i]} + b + e_i, \qquad h_j \sim N(0,\sigma_h^2),\ \ b \sim N(0,\sigma_b^2)$$

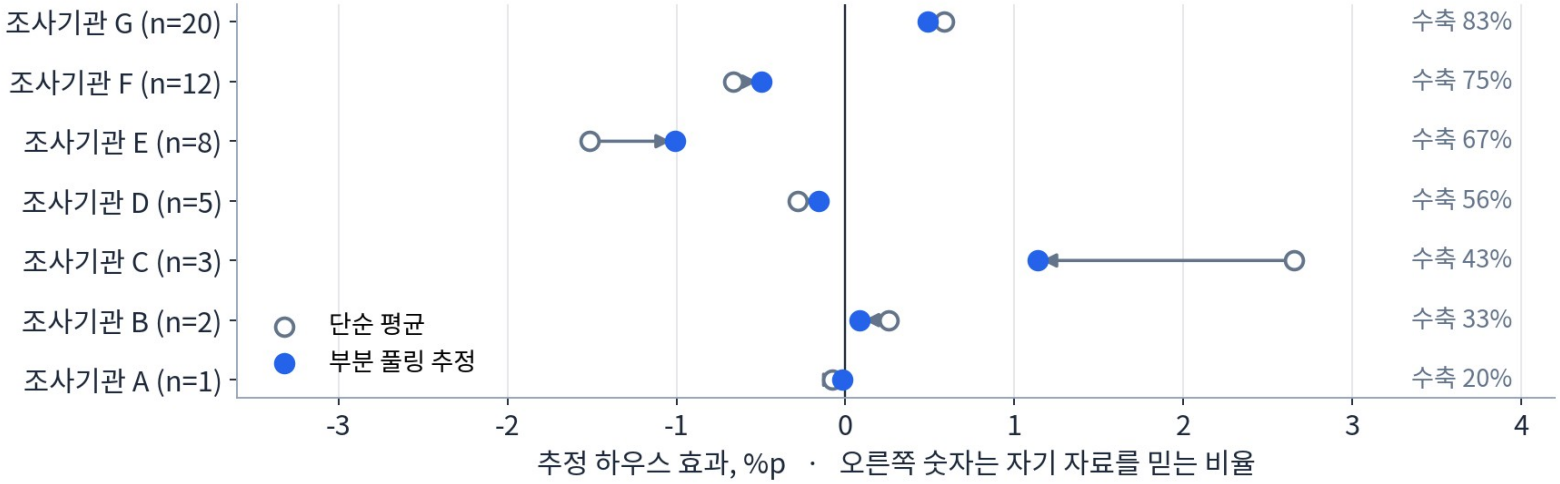
$$\hat{h}_j = \underbrace{\frac{n_j\sigma_h^2}{n_j\sigma_h^2+\sigma_e^2}}_{\text{shrinkage}}\ \bar{y}_j^{\text{resid}}$$

조사 건수 n이 적은 기관일수록 자기 평균을 덜 믿고 0 쪽으로 강하게 수축한다

03. 여론조사 관측 모형

부분 풀링은 자료가 적은 기관의 극단값을 걸러낸다

합성 예시: 조사기관 7곳, σ_h = 1.0, 조사당 오차 σ_e = 2.0 (%p).



조사 3건짜리 기관 C의 +2.7은 수축 후 +1.1 — 한두 건의 이상치가 평균을 흔들지 못한다

03. 여론조사 관측 모형

공통 편향 b는 데이터로 식별되지 않으므로 과거에서 빌려온다

모든 조사가 함께 빗나가면 여론조사끼리 비교해서는 알 수 없다. 사전분포가 유일한 정보원이다.

1	**식별 불가**	b는 모든 조사에 똑같이 더해지므로 여론조사 데이터 안에서는 추정되지 않는다
2	**과거에서 학습**	과거 선거의 '최종 여론조사 평균 − 실제 결과'로 σ_b의 사전분포를 만든다
3	**방향은 모른다**	평균은 0으로 두고 폭만 학습한다. 지난번 방향을 그대로 빼면 과적합이 된다

b가 곧 앞 강의의 공통 충격 η다 — 계층 모형은 그것을 '여론조사 업계의 편향'으로 해석한다

04

상관 구조

요인 상관 구조

주들이 함께 움직이는 정도를 공분산 행렬로 명시한다

04. 요인 상관 구조

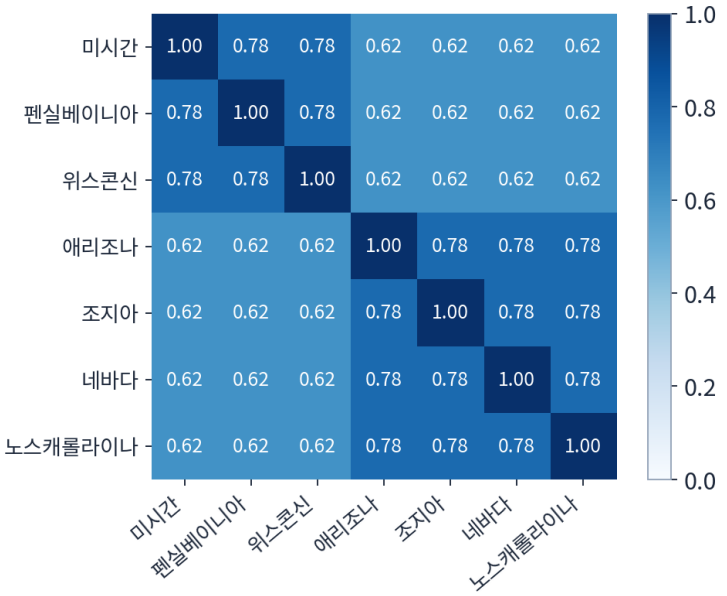
전국·권역·주 세 층의 요인으로 공분산을 만든다

R = 권역 소속 행렬(러스트벨트 / 선벨트). σ_b = 2.0, σ_r = 1.0, σ_ε = 1.2 (%p, 예시).

$$\Sigma = \sigma_b^2 \mathbf{1}\mathbf{1}^\top + \sigma_r^2 RR^\top + \sigma_\varepsilon^2 I$$

읽는 법

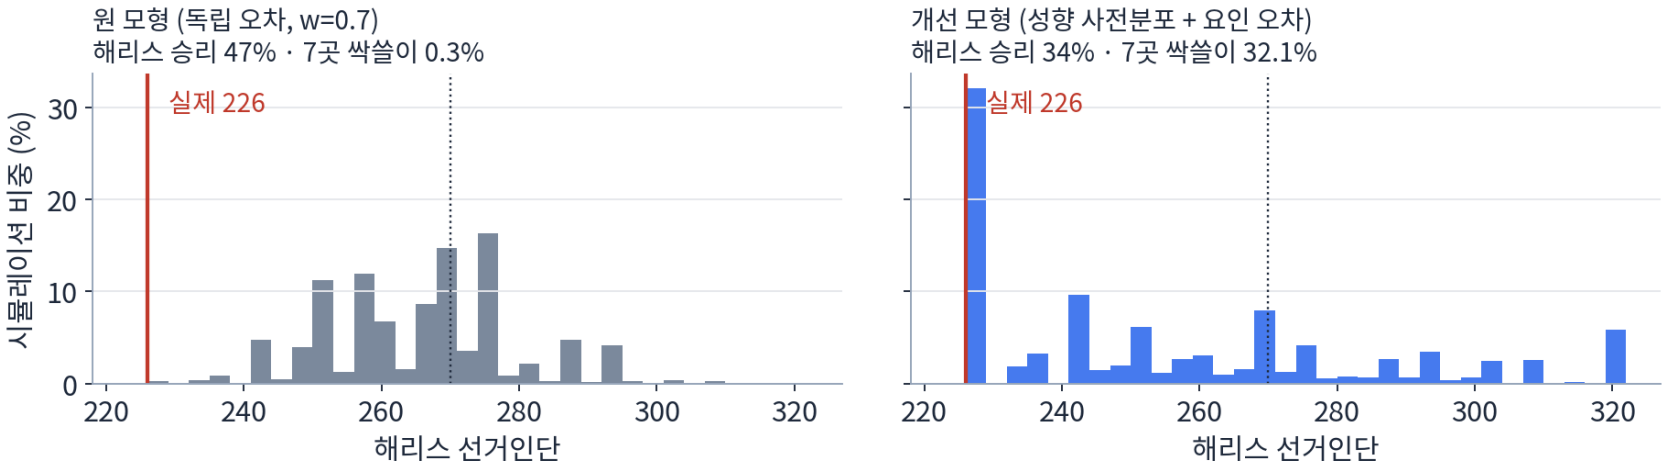
- 같은 권역 상관 0.78, 다른 권역 0.62
- 러스트벨트 3곳은 함께 넘어간다
- Economist 모형은 인구 구성 유사도로 상관을 만든다



04. 요인 상관 구조

개선 모형에서는 실제 결과가 가장 흔한 시나리오가 된다

같은 2024 최종 여론조사, 몬테카를로 5만 회. 경합주 외 해리스 확보 선거인단 226 가정.



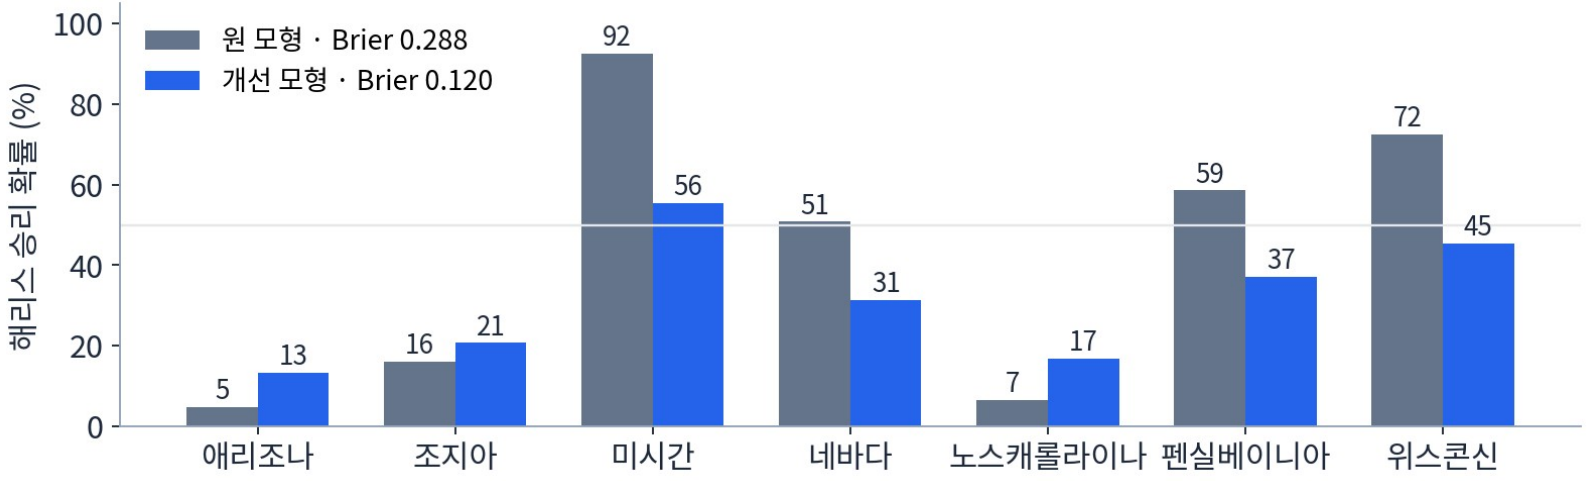
트럼프 7곳 싹쓸이 확률 — 원 모형 0.3%, 개선 모형 32%

※ 설명용 재구성 모형. 전국 환경 0, σ 값은 예시이며 과거 선거로 학습해야 한다

04. 요인 상관 구조

주별 확률은 덜 자신만만해지고 방향은 맞아진다

막대 = 각 모형의 해리스 승리 확률. 실제로는 7곳 모두 트럼프 승리(해리스 0%).



원 모형은 미시간 92%·위스콘신 72%로 과신했고, 개선 모형은 모든 주에서 트럼프 우세 또는 접전

05

검증

검증과 운영

적중 여부가 아니라 확률의 품질을 채점한다

05. 검증과 운영

확률 예측은 적중률이 아니라 채점 규칙으로 평가한다

Proper scoring rule: 참 확률을 말할 때 기대 점수가 가장 좋아지는 규칙. Brier는 낮을수록, 로그 점수는 높을수록 좋다.

$$\text{Brier} = \frac{1}{S}\sum_{s}(p_s - y_s)^2, \qquad \text{LogScore} = \log p(\text{outcome})$$

지표	원 모형	개선 모형	해석
주별 Brier (7곳)	0.288	0.120	0.25 = 동전 던지기. 원 모형은 그보다 나빴다
싹쓸이 로그 점수	−5.84	−1.14	실제 결과에 준 확률 0.3% vs 32%
해리스 승리 확률	47%	34%	둘 다 틀릴 수 있지만 과신의 정도가 다르다

한 번의 선거로는 운과 실력을 구분할 수 없다 — 여러 선거·여러 주로 누적 채점한다

05. 검증과 운영

모든 설정값은 과거 선거로 학습하고 사전에 고정한다

사후에 결과를 보고 σ나 전국 환경을 맞추면 사후 확증 편향(hindsight bias)이 된다.

STEP 1

학습

- 2000~2020 선거 자료
- σ_b, σ_r, σ_ε 추정
- 하우스 효과 사전분포

▶

STEP 2

백테스트

- 선거마다 그 시점 정보만
- Brier·로그 점수 누적
- 캘리브레이션 곡선

▶

STEP 3

사전 고정

- 선거 전 설정 공개
- 민감도 표 함께 공개
- 사후 수정은 다음 주기에

앞 페이지의 개선 모형 수치도 사후 설정이다 — 실무에서는 STEP 1의 학습값을 써야 한다

05. 검증과 운영

더 나아갈 수 있는 네 가지 확장

모두 베이지안 틀 안에서 기존 모형에 블록으로 붙는다.

다층 모형	스태킹	예측시장	개표 나우캐스트
인구집단별 추정	**모형 평균**	**추가 증거**	**선거 당일 갱신**
다층 회귀 + 사후층화로 여론조사가 적은 주도 추정	여러 모형을 교차검증 점수로 가중 결합	베팅 시장 가격을 또 하나의 관측으로 결합	개표 진행에 따라 칼만 필터로 실시간 갱신
MRP	Bayesian stacking	Prediction markets	Election night

블록을 더할수록 설정은 늘어나므로, 늘어난 만큼 백테스트로 검증해야 한다

05. 검증과 운영

같은 도구가 금융 모형에서 그대로 쓰인다

선거 예측의 각 블록에는 이미 익숙한 금융 대응물이 있다.

선거 예측 블록	금융 대응	공통 원리
펀더멘털 사전분포 + 여론조사	Black-Litterman: 균형수익률 + 투자자 전망	사전분포와 증거를 정밀도로 결합
상태공간 · 칼만 필터	동적 베타 · 시변 팩터 노출 추정	숨은 상태를 잡음 관측으로 추적
하우스 효과 수축	애널리스트 추정치 · 공분산 수축추정	자료가 적을수록 공통값으로 수축
전국·권역·주 요인	시장·산업·개별 팩터 리스크 모형	공통 요인이 동반 손실을 만든다

선거 예측을 이해하면 포트폴리오 리스크 모형의 설계 논리를 그대로 읽을 수 있다

SUMMARY

개선의 핵심은 설정값을 추정값으로 바꾸는 것이다

원 모형의 약점과 개선 도구를 한 번 더 짝지어 정리한다.

사전분포	**성향 + 전국 환경**	과거 결과를 통째로 복사하지 않고 안정적인 부분만 가져온다
가중치	**칼만 이득**	여론조사 신뢰도는 두 불확실성의 비율로 추정된다
여론조사	**계층 모형 · 수축**	하우스 효과는 추정하고, 공통 편향은 과거에서 폭을 배운다
상관 · 검증	**요인 공분산 · 채점**	함께 빗나가는 구조를 명시하고, 사전 고정 후 누적 채점한다

남는 손잡이는 과거 선거로 학습하고, 선거 전에 고정해 공개한다

선거 예측의 베이지안 확장

손잡이를 줄이고,
불확실성을 추정하라

사전분포 · 상태공간 · 계층 모형 · 요인 상관 · 채점 규칙