강의 통합본 · 이론과 예제

베이지안 시계열 분석

AR 모형에서 베이지안 예측까지

하나의 AR(2) 예제로 따라가는 5부 구성 — 시계열 기초 · AR 모형 · 최대우도 · 베이지안 · 예측과 적용

2026. 9

요지

베이지안 시계열은 모수의 불확실성까지 예측에 담는다

추정값 하나 대신 모수의 분포 전체로 예측한다

MLE와 추정값은 거의 같지만, 데이터가 짧을수록 예측구간을 더 정직하게 넓힌다

1 AR 모형

오늘 값을 어제·그제 값의 가중합과 새 충격으로 설명한다. 계수가 정상성 삼각형 안에 있어야 한다.

2 MLE와 베이지안

예제(T = 300)에서 둘째 계수 추정값은 0.505와 0.502로 사실상 같다. 차이는 결과를 표현하는 방식이다.

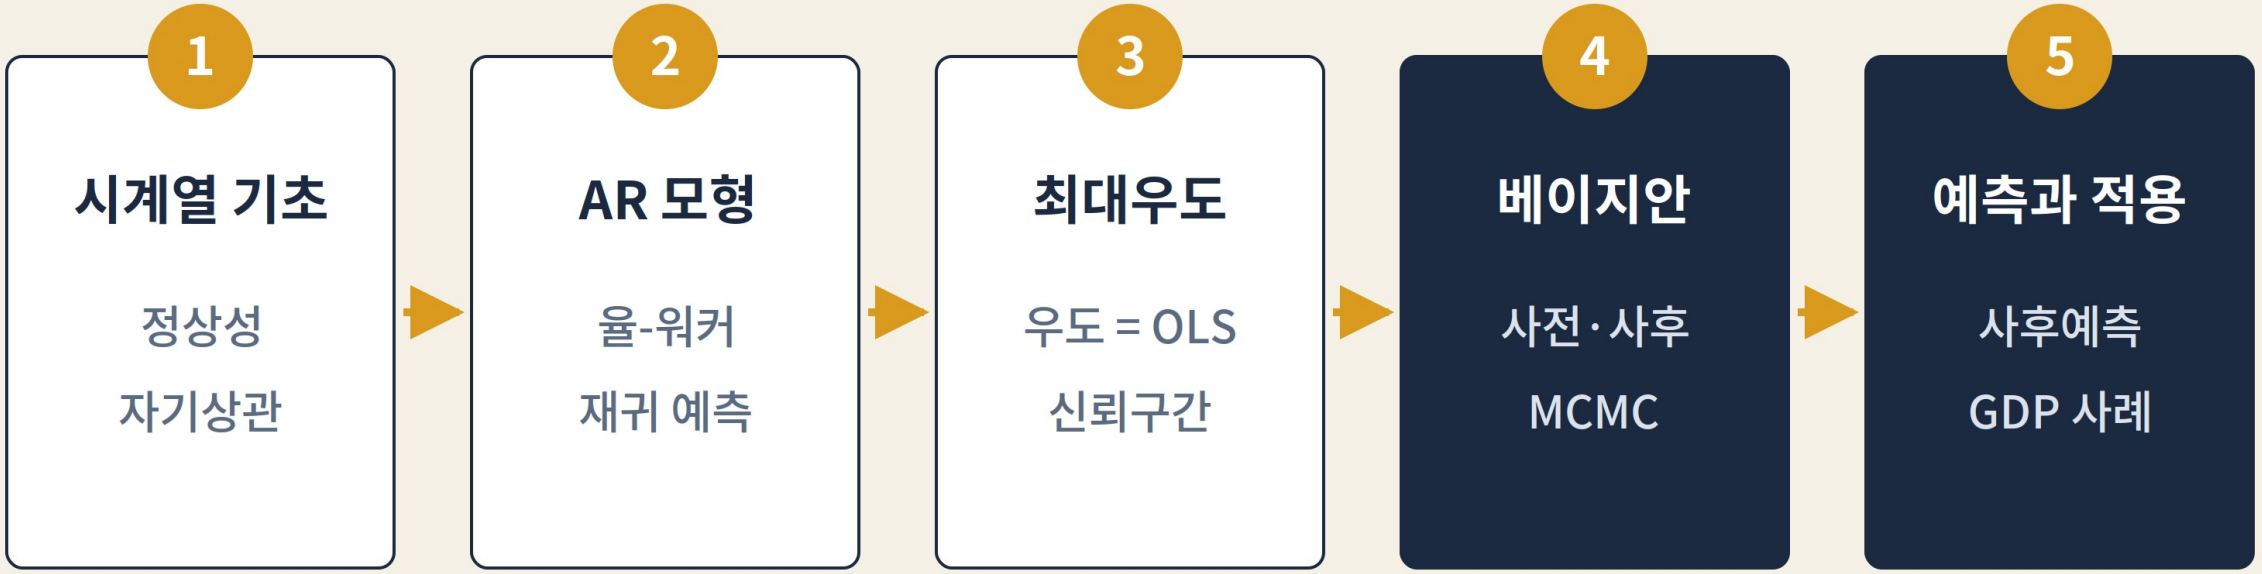
3 예측

베이지안 예측구간은 T = 300에서 1.8%, T = 50의 5기 앞에서 6.4% 더 넓다. 모수 오차가 반영된 결과다.

구성

다섯 부분을 하나의 예제로 연결한다

같은 AR(2) 예제 하나로 끝까지 간다



모수를 하나의 값으로 (빈도주의)

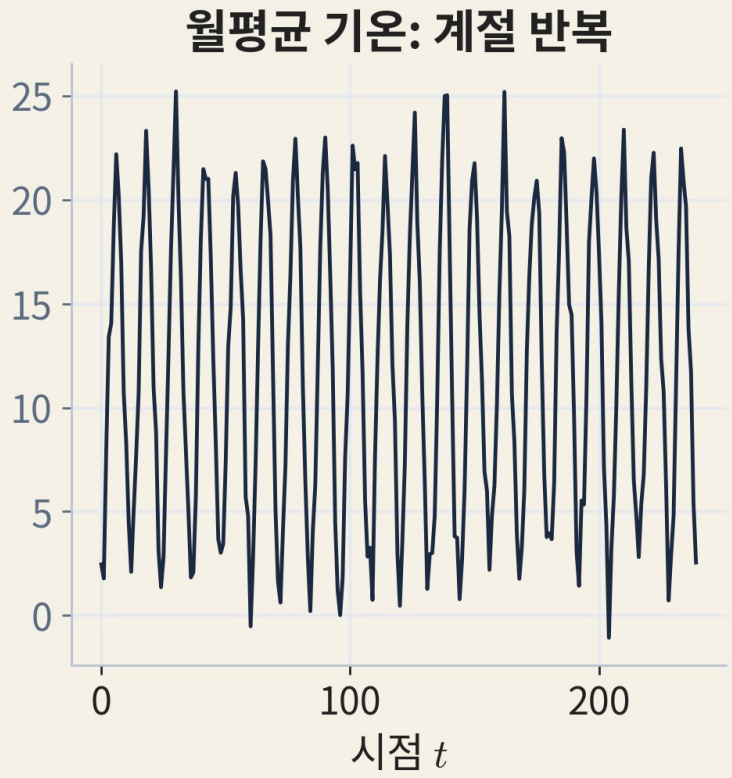
모수를 분포로 (베이지안)

PART 1

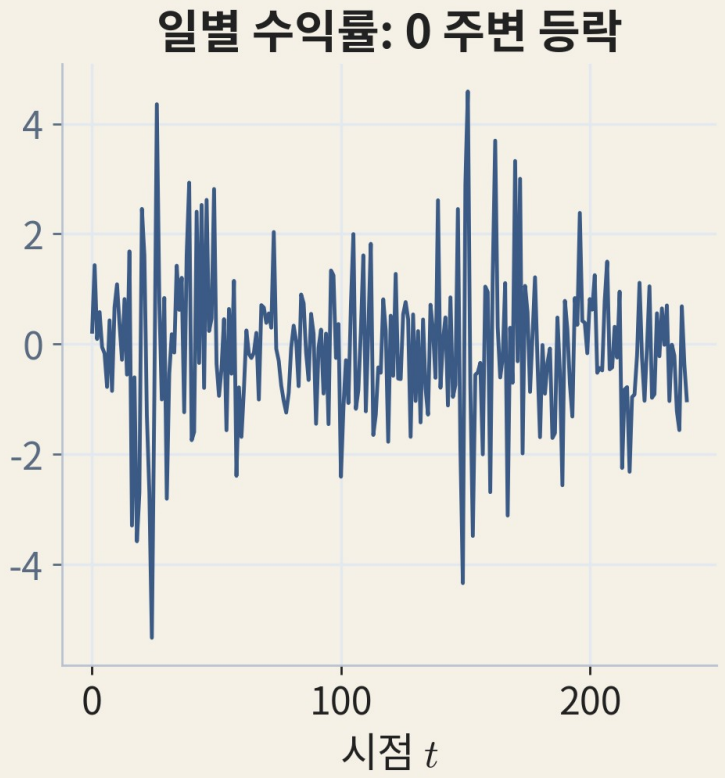
시계열 기초

순서가 있는 데이터 · 정상성 · 자기상관

시계열은 관측 순서 자체가 정보인 데이터다







순서를 섞으면 계절 반복·추세·변동성 군집이 모두 사라진다

세 가지 기호로 시계열 모형을 쓴다

관측값 계열

$$x_1,\ x_2,\ \ldots,\ x_T$$

시간 순으로 놓인 T개의 값

아래첨자 t가 시점이다. 순서를 바꾸면 다른 데이터가 된다.

시차 (lag)

$$x_{t-k} \quad (\text{시차 } k)$$

k 시점 전의 값

어제 값은 시차 1, 그제 값은 시차 2. AR 모형의 재료가 된다.

백색잡음 (white noise)

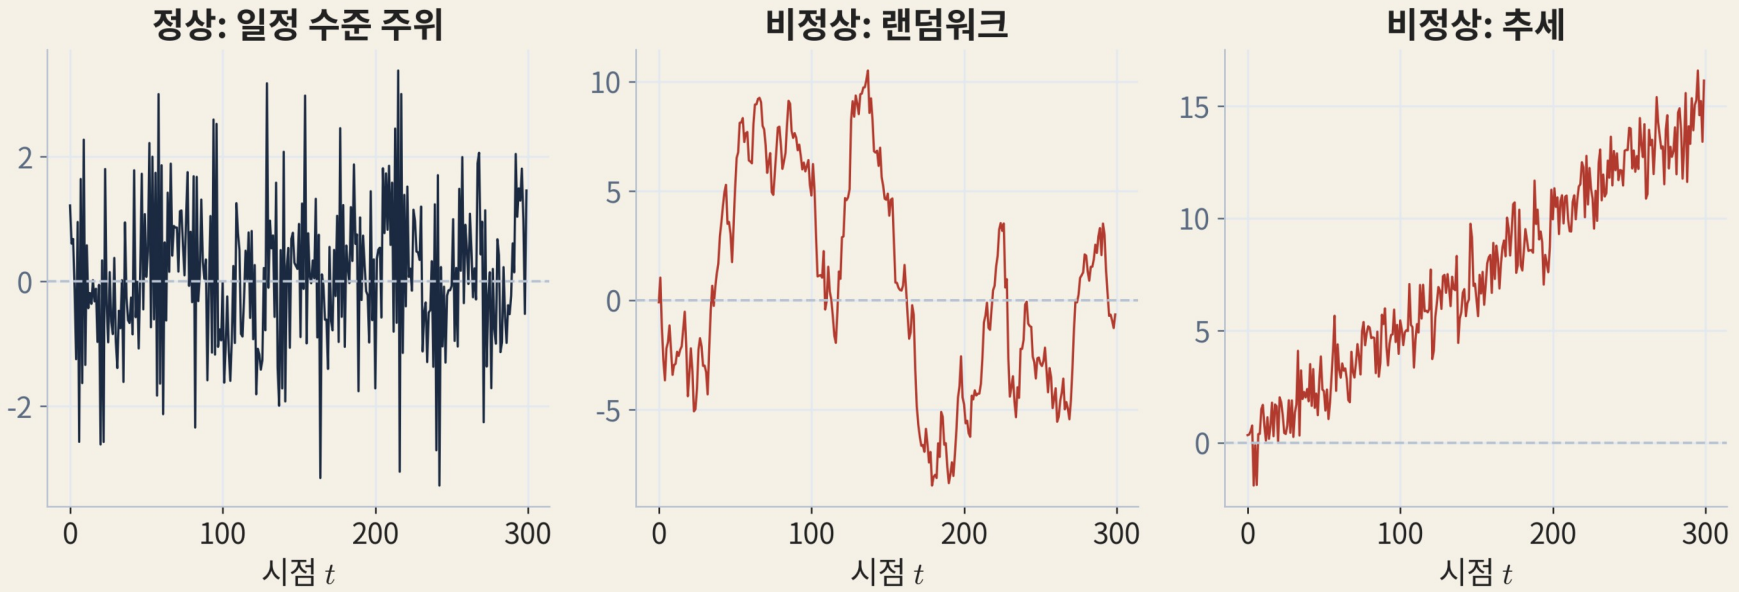
$$\varepsilon_t \overset{\text{iid}}{\sim} N(0,\ \sigma^2)$$

예측할 수 없는 순수한 충격

서로 독립이고 평균 0, 분산이 일정하다. 모형이 설명하지 못하는 부분이다.

정상 시계열은 평균과 상관 구조가 시간에 따라 변하지 않는다

$$E[x_t] = \mu, \qquad \mathrm{Cov}(x_t,\ x_{t-k}) = \gamma_k$$



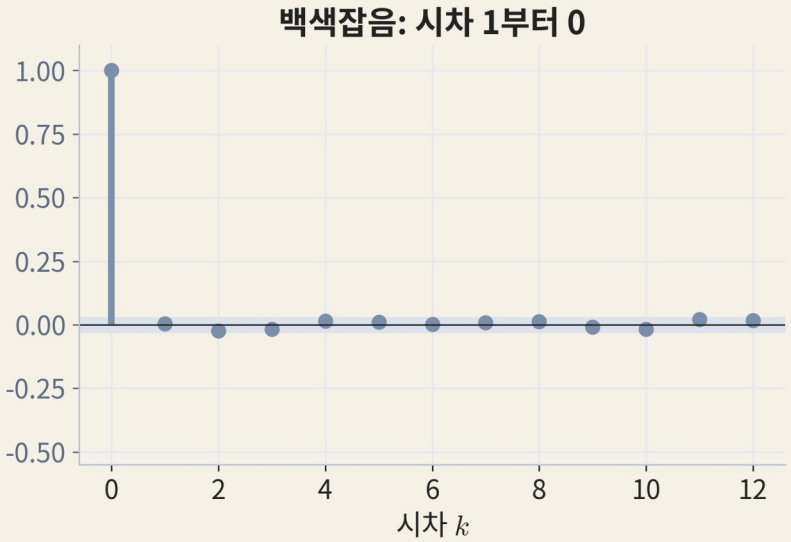
AR 모형의 추정·예측 이론은 정상성을 전제로 한다 — 비정상이면 차분 등으로 먼저 바꾼다

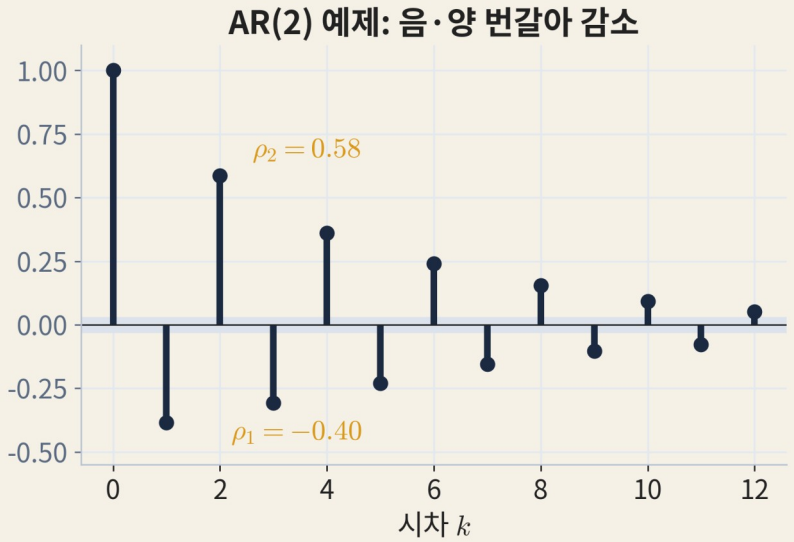
자기상관은 k 시점 떨어진 값끼리 얼마나 닮았는지 잰다

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \frac{\mathrm{Cov}(x_t,\ x_{t-k})}{\mathrm{Var}(x_t)}$$

자기상관함수(ACF) 읽는 법

시차별 상관을 막대로 그린다. 파란 띠 밖 막대는 우연으로 보기 어려운 상관이다.





백색잡음은 기억이 없고, AR(2) 예제는 음·양을 번갈아 가며 서서히 기억을 잃는다

PART 2

AR 모형

자기회귀 · 정상성 조건 · 율-워커 방정식 · 충격반응 · 예측

AR 모형은 오늘 값을 과거 값의 가중합과 새 충격으로 설명한다

AR(1): 한 시점 전까지

$$x_t = \phi\, x_{t-1} + \varepsilon_t$$

AR(2): 두 시점 전까지

$$x_t = \phi_1 x_{t-1} + \phi_2 x_{t-2} + \varepsilon_t$$

AR(p): p 시점 전까지

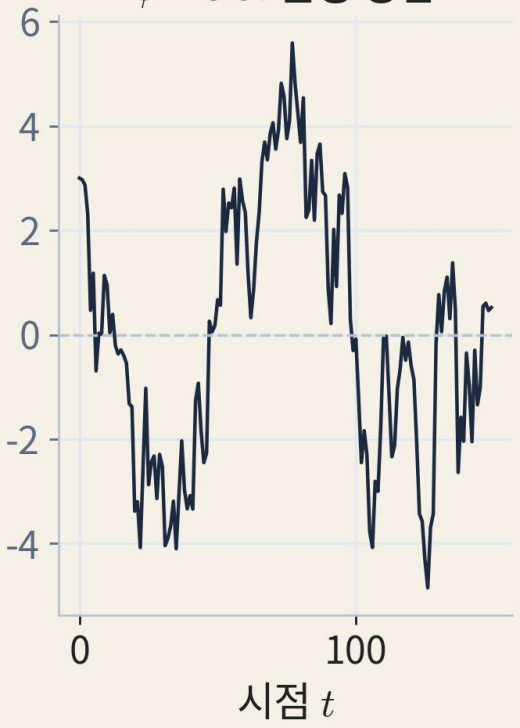
$$x_t = \phi_1 x_{t-1} + \phi_2 x_{t-2} + \cdots + \phi_p x_{t-p} + \varepsilon_t$$

계수의 뜻

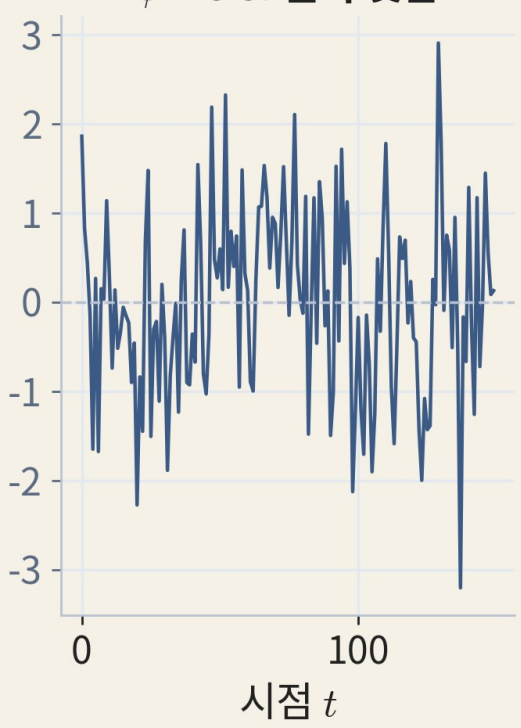
- 계수 절댓값이 클수록 과거를 오래 기억한다
- 음의 계수는 방향을 뒤집는다 (지그재그)
- 충격이 매 시점 새 정보를 더한다
- 차수 p는 몇 시점 전까지 볼지 정한다
- AR = AutoRegressive, 자기 자신에 회귀

계수 하나가 시계열의 성격을 바꾼다

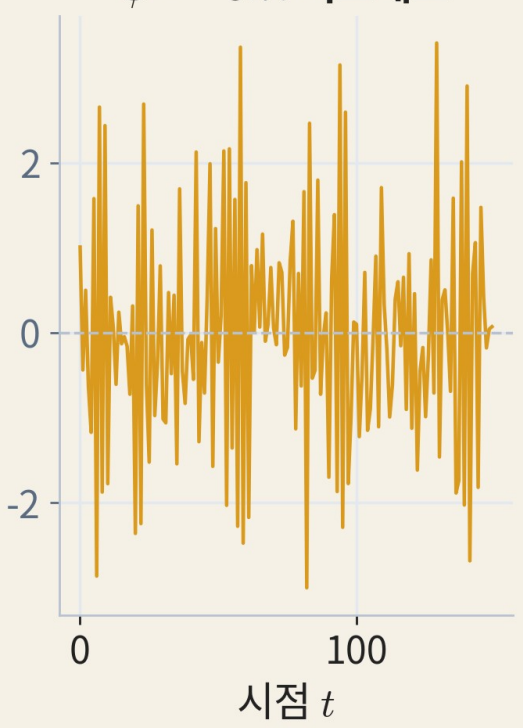
$\phi = 0.9$: 관성 강함



$\phi = 0.3$: 빨리 잊음



$\phi = -0.7$: 지그재그



$\phi = 1$: 랜덤워크



계수가 1이면 충격이 사라지지 않는 랜덤워크 — 정상성이 깨진다

과정 예제: 계수 −0.2와 0.5인 AR(2)를 300개 만든다

모든 PART에서 쓰는 예제 모형

$$x_t = -0.2\,x_{t-1} + 0.5\,x_{t-2} + \varepsilon_t, \qquad \sigma = 0.1$$

T = 300
관측 길이 (앞 200개는 버림)

seed 7
재현용 난수 시드

0.126
시계열 표준편차 (이론값)

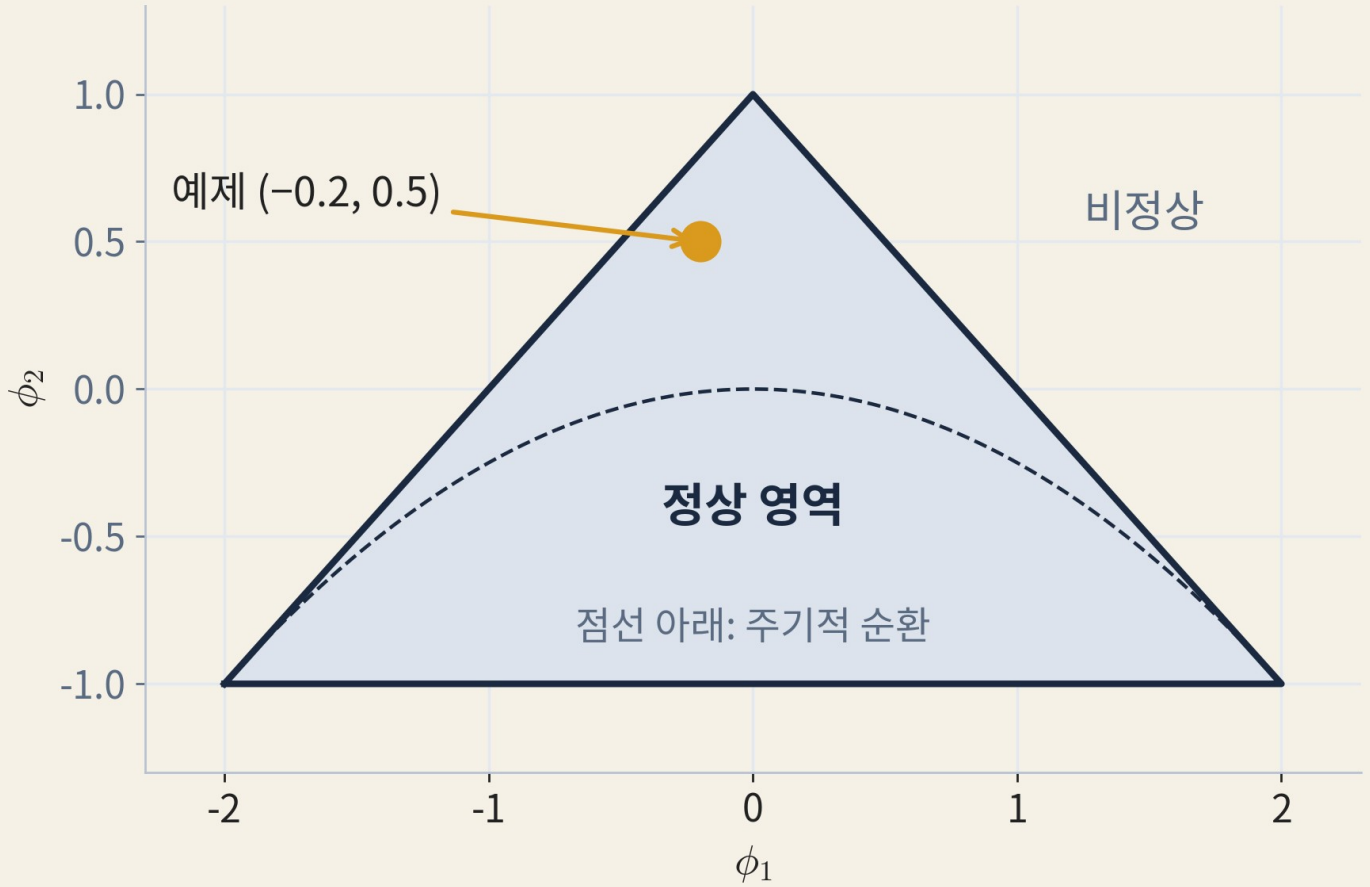
−0.1726
첫 관측값

처음 다섯 값: −0.1726, 0.2241, −0.0817, 0.2157, 0.1039

이후 모든 추정·예측은 이 한 계열로 계산하고, 참값과 비교해 검증한다

예제 데이터: AR(2) 계수 −0.2, 0.5, 잡음 표준편차 0.1, T = 300, seed 7 (시뮬레이션)

두 계수가 삼각형 안에 있어야 AR(2)가 정상이다



정상성 조건 (AR(2))

$$\phi_1 + \phi_2 < 1, \quad \phi_2 - \phi_1 < 1, \quad |\phi_2| < 1$$

- 세 부등식이 만드는 삼각형 안쪽이 정상 영역
- 예제 (−0.2, 0.5)는 안쪽 → 정상
- 점선 아래는 주기적으로 순환하는 영역
- 밖으로 나가면 분산이 폭발한다

율-워커 방정식으로 자기상관을 손으로 계산한다

① 시차 1

$$\rho_1 = \frac{\phi_1}{1-\phi_2} = \frac{-0.2}{0.5} = -0.4$$

② 점화식 (시차 2 이상)

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2}$$

③ 시차 2

$$\rho_2 = (-0.2)(-0.4) + 0.5 = 0.58$$

④ 분산

$$\gamma_0 = \frac{(1-\phi_2)\,\sigma^2}{(1+\phi_2)\{(1-\phi_2)^2 - \phi_1^2\}} = 0.0159$$

이론값 −0.40, 0.58, −0.316, 0.353 — 표본 ACF와 거의 같다 · 표준편차 0.126

충격 하나는 부호를 바꾸며 서서히 사라진다

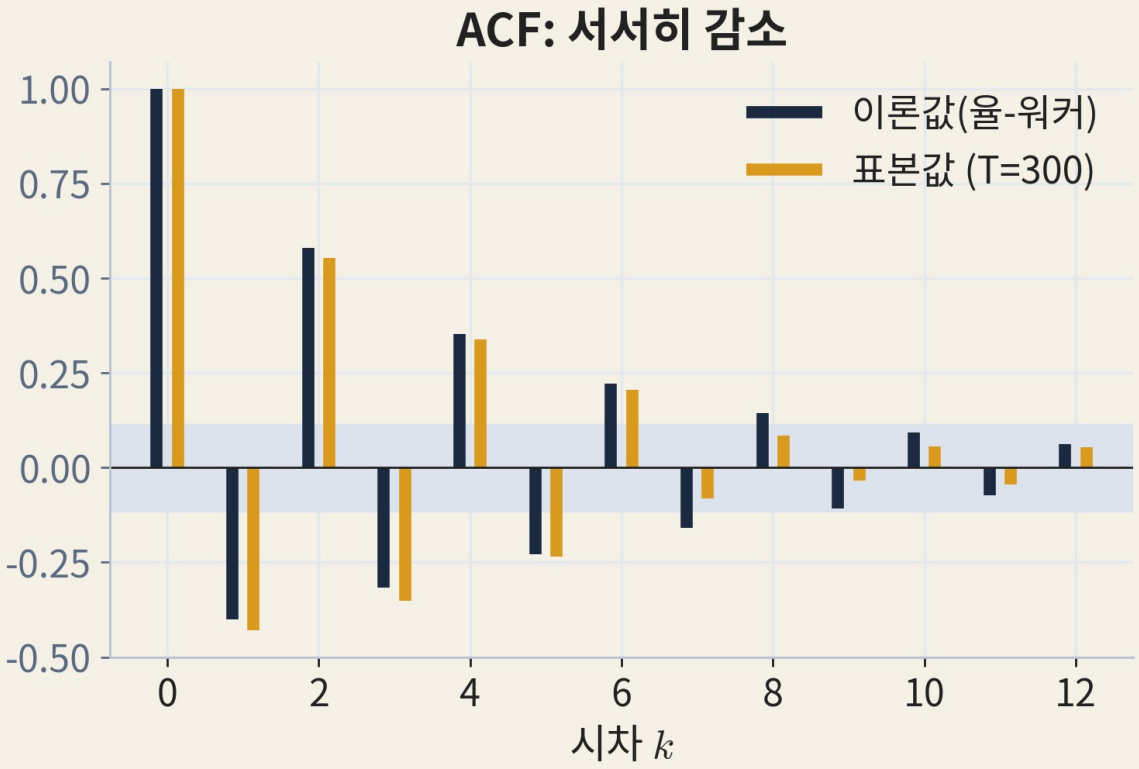
$$\psi_0 = 1, \quad \psi_1 = \phi_1, \quad \psi_k = \phi_1 \psi_{k-1} + \phi_2 \psi_{k-2}$$

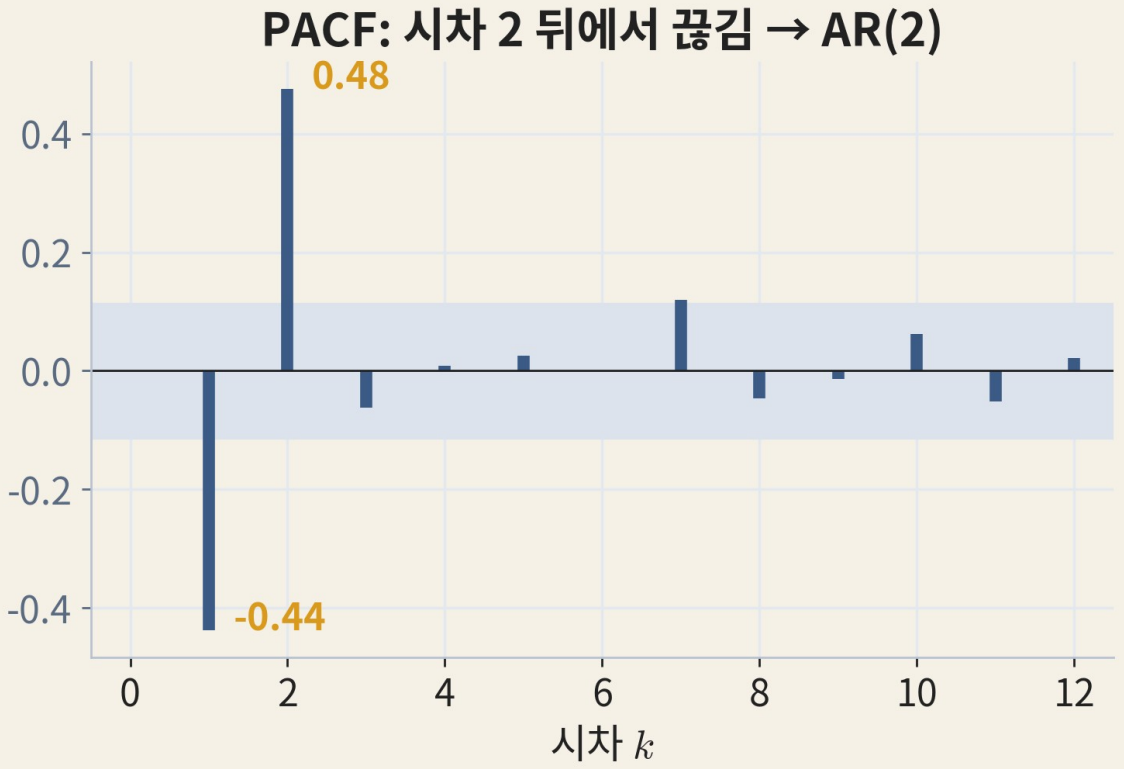


충격반응 계수 읽기

- 시점 0의 충격 1이 k 시점 뒤 남는 크기
- 1 → −0.2 → 0.54 → −0.208 → 0.312
- 둘째 계수 0.5가 짝수 시차를 키운다
- 0으로 수렴 = 정상 과정

PACF가 시차 2 뒤에서 끊기면 AR(2)를 고른다



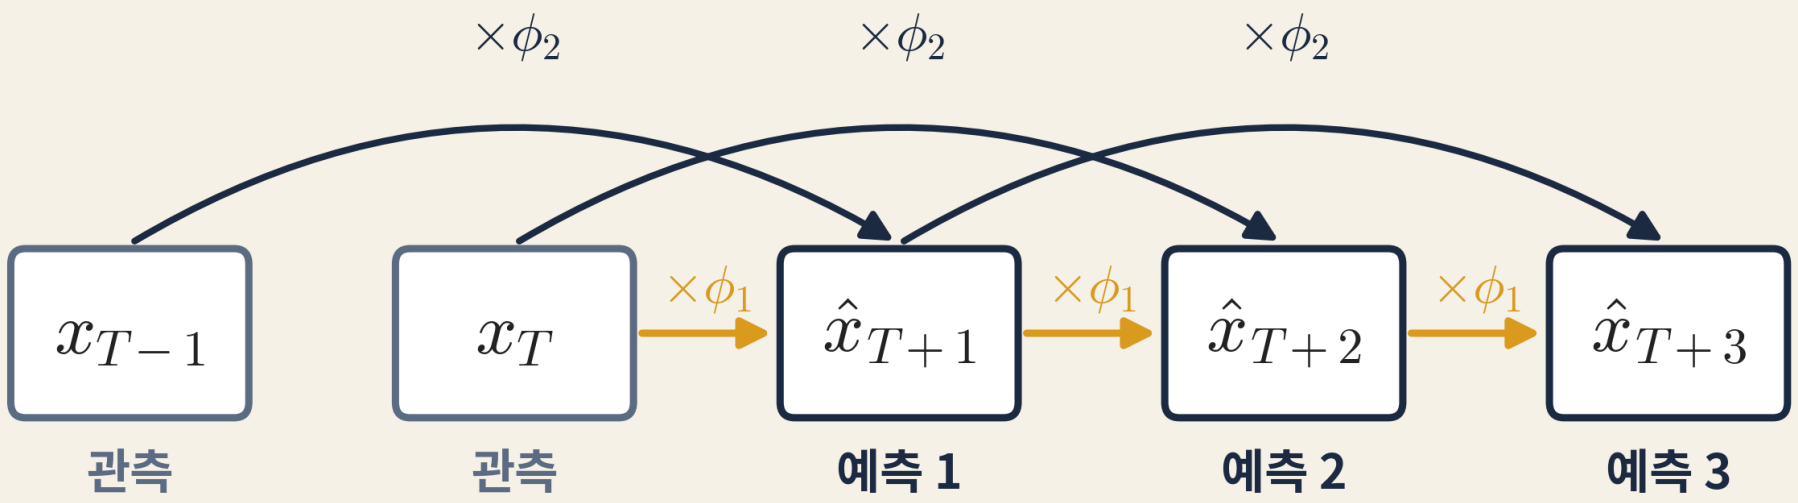


ACF는 서서히 줄고 PACF는 차수 뒤에서 끊긴다 — AR 차수 선택의 기본 규칙

예제 데이터: AR(2) 계수 −0.2, 0.5, 잡음 표준편차 0.1, T = 300, seed 7 (시뮬레이션)

예측은 앞선 예측값을 다시 넣는 재귀 계산이다

$$\hat{x}_{T+h} = \phi_1 \hat{x}_{T+h-1} + \phi_2 \hat{x}_{T+h-2}$$



예측값이 다음 예측의 입력이 된다 — 미래 충격은 평균 0이라 빠진다

예측 오차는 먼 미래일수록 커지다가 한계에 수렴한다

h기 앞 예측 오차의 분산

$$\mathrm{Var}(x_{T+h} - \hat{x}_{T+h}) = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2$$

예측 시점	T+1	T+2	T+3	T+4	T+5	장기 한계
예측 표준편차	0.100	0.102	0.115	0.117	0.121	**0.126**

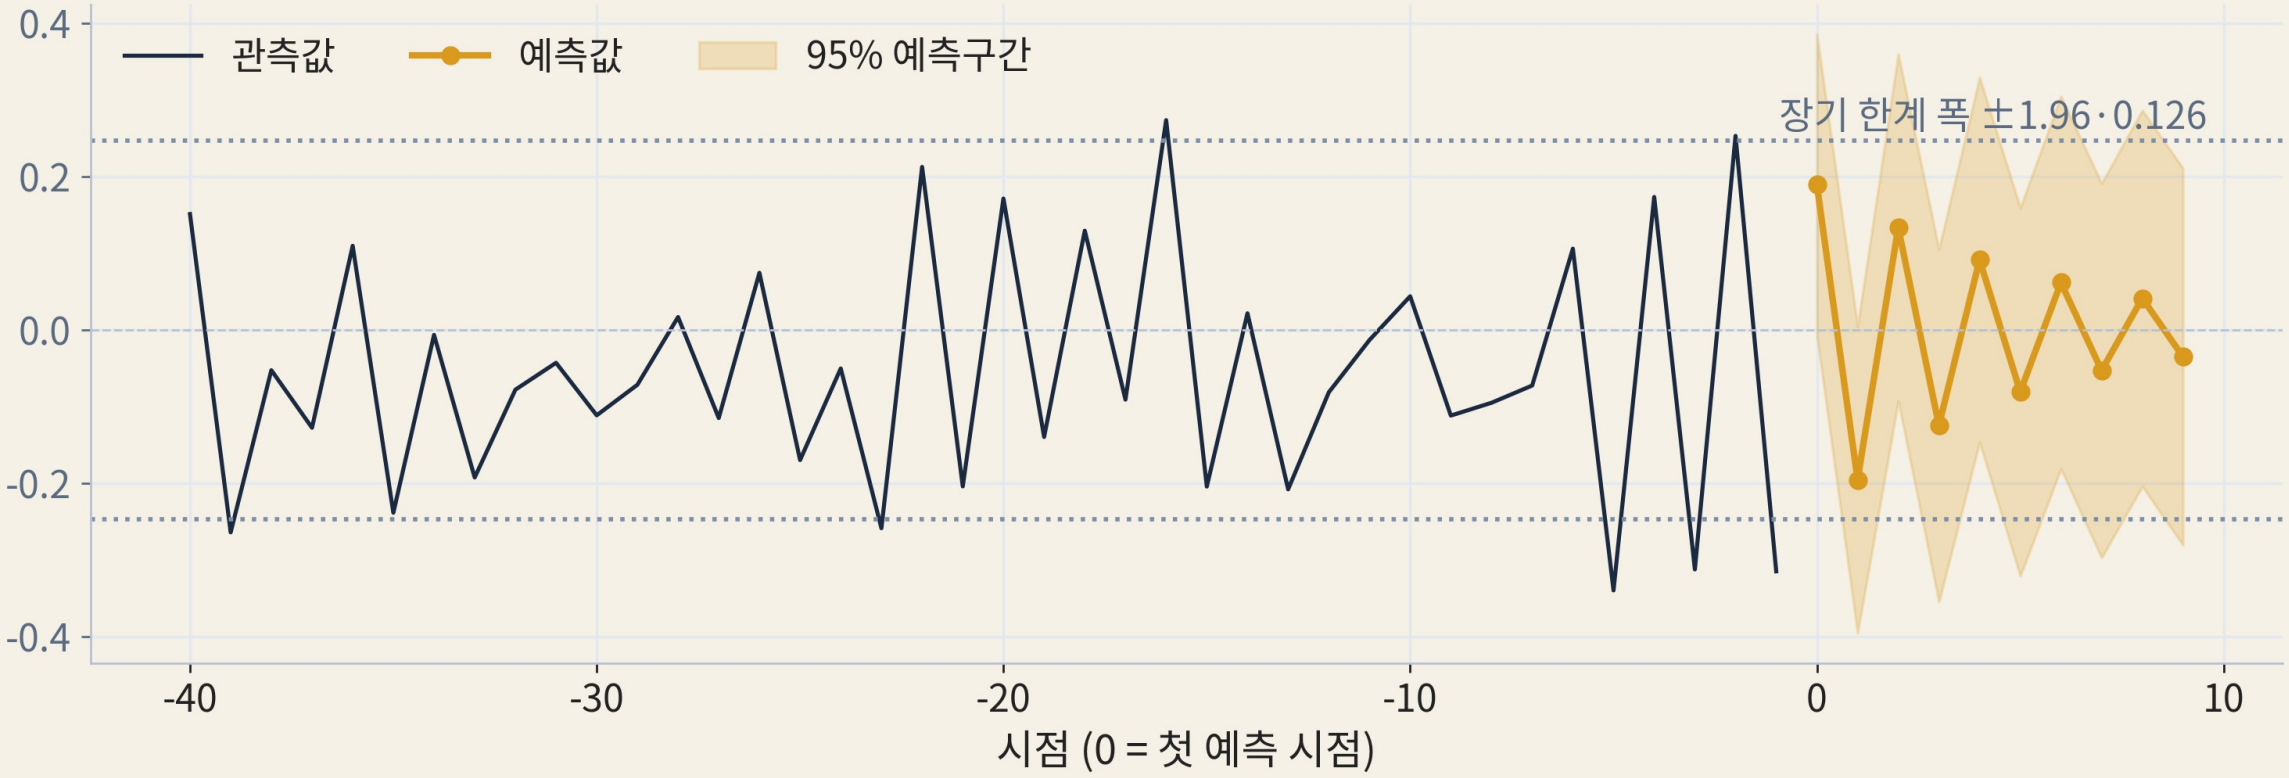
첫 시점

오차는 새 충격 하나뿐이다 → 표준편차 0.1 (잡음 크기와 같음)

먼 미래

지난 충격의 잔향이 쌓여 시계열 전체 표준편차 0.126에 수렴한다

95% 예측구간은 장기 한계 폭 안에서 부채꼴로 벌어진다



이 구간은 계수를 정확히 안다고 가정한 것 — 추정하면 불확실성이 더해진다

예제 데이터: AR(2) 계수 −0.2, 0.5, 잡음 표준편차 0.1, T = 300, seed 7 (시뮬레이션)

PART 3

최대우도 추정

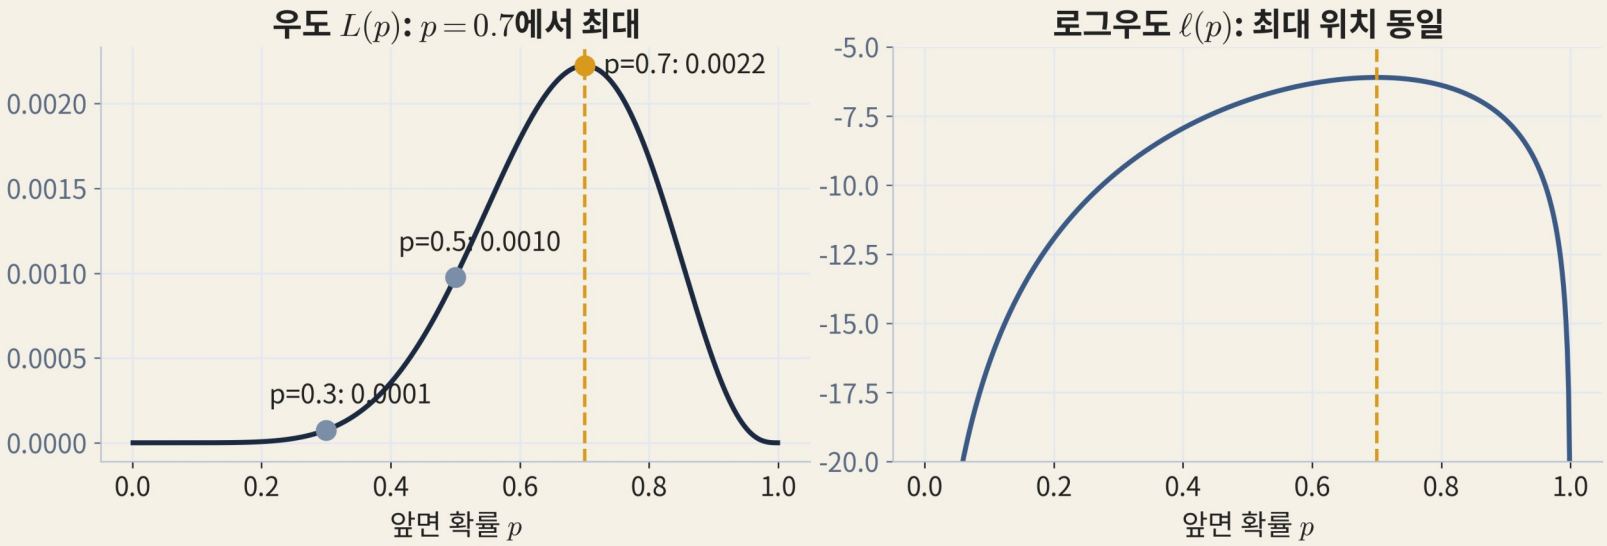
우도 · 조건부 우도 = 최소제곱 · 표준오차 · 신뢰구간

우도는 "이 모수라면 지금 데이터가 나올 가능성"이다

$$L(\theta) = p(x_1, \ldots, x_T \mid \theta)$$

확률과 무엇이 다른가

확률은 모수를 고정하고 데이터를 바꾼다. 우도는 데이터를 고정하고 모수를 바꾼다.



우도가 가장 큰 모수를 추정값으로 삼는 방법이 최대우도 추정(MLE)이다

예제: 동전 10번 중 앞면 7번이면 추정값은 0.7이다

① 우도 (독립 시행의 곱)

$$L(p) = p^7(1-p)^3$$

② 로그우도 (곱 → 합)

$$\ell(p) = 7\log p + 3\log(1-p)$$

③ 미분해서 0으로

$$\frac{d\ell}{dp} = \frac{7}{p} - \frac{3}{1-p} = 0 \;\Rightarrow\; \hat{p} = 0.7$$

왜 로그를 취하나

- 작은 확률의 곱은 0에 가까워져 다루기 어렵다
- 로그는 증가함수 → 최대 위치가 같다
- 결과는 직관과 같은 표본비율 7/10

시계열도 같은 절차: 우도를 쓰고, 로그를 취하고, 최대화한다

AR 모형에서 조건부 최대우도는 최소제곱(OLS)과 같다

① 과거가 주어졌을 때 한 시점의 분포

$$x_t \mid \phi, \sigma \;\sim\; N(\phi_1 x_{t-1} + \phi_2 x_{t-2},\; \sigma^2)$$

② 조건부 로그우도 (첫 두 값을 조건으로)

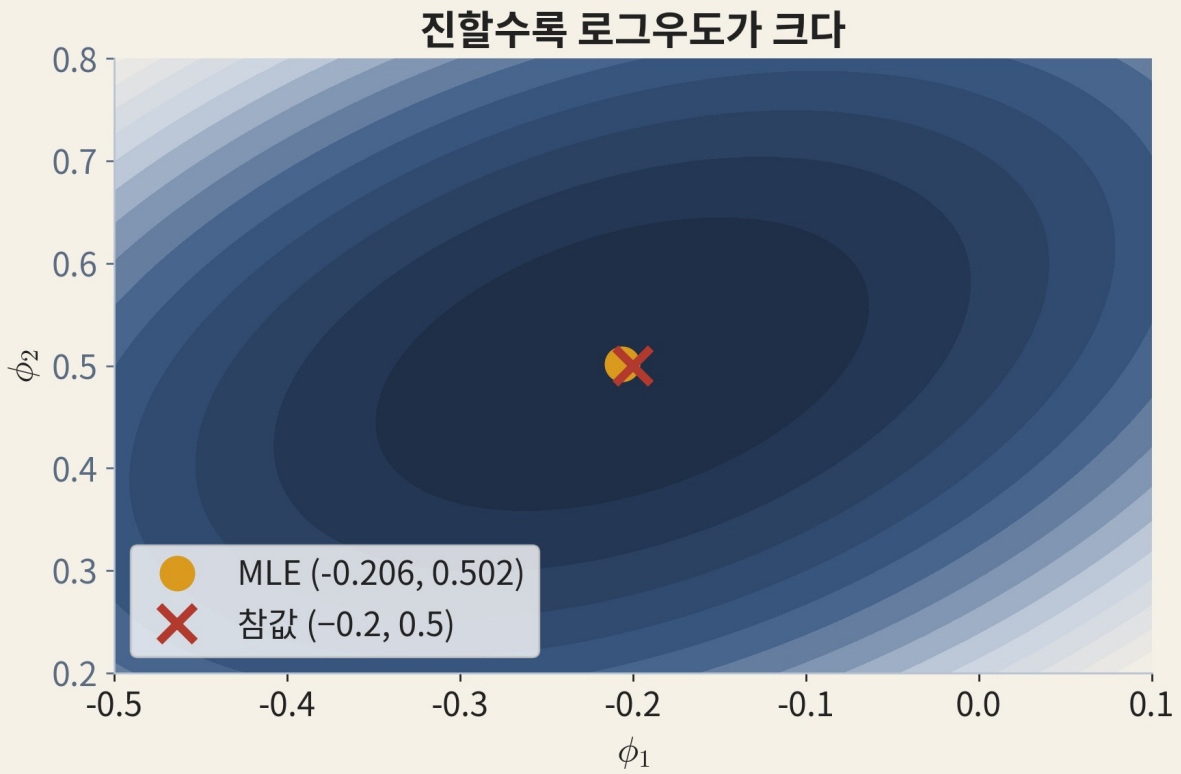
$$\ell(\phi, \sigma) = -\frac{T-2}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{t=3}^{T}\left(x_t - \phi_1 x_{t-1} - \phi_2 x_{t-2}\right)^2$$

③ 계수 추정: σ와 무관하게 오차제곱합 최소화

$$\hat{\phi}_{\mathrm{MLE}} = \arg\min_{\phi} \sum_t \left(x_t - \phi_1 x_{t-1} - \phi_2 x_{t-2}\right)^2 = \hat{\phi}_{\mathrm{OLS}}$$

오차제곱합을 줄이는 계수가 곧 우도를 최대로 만드는 계수다

예제 데이터의 MLE는 참값 근처에 놓인다



방법	ϕ_1	ϕ_2	σ
참값	−0.2	0.5	0.1
정확 MLE	−0.215	0.505	0.0988
조건부 MLE = OLS	−0.206	0.502	0.0985

두 MLE는 왜 다른가

정확 MLE는 첫 두 관측의 분포까지 우도에 넣는다. T = 300에서는 차이가 소수 둘째 자리 이하다.

예제 데이터: AR(2) 계수 −0.2, 0.5, 잡음 표준편차 0.1, T = 300, seed 7 (시뮬레이션)

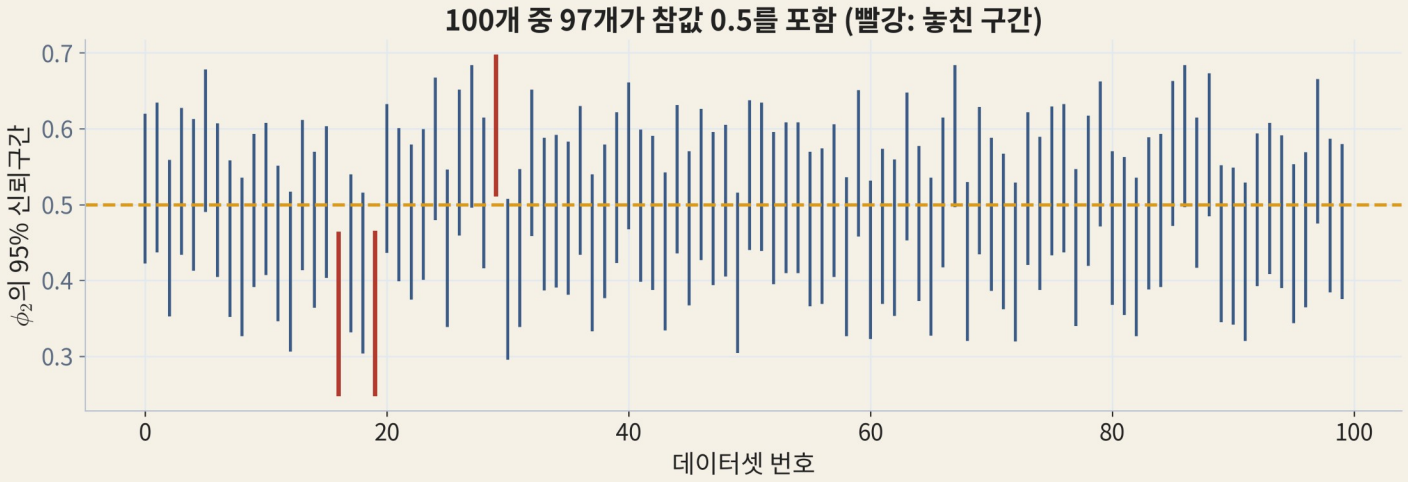
표준오차는 데이터 길이의 제곱근에 반비례한다

표준오차

$$\mathrm{SE}(\hat{\phi}) \propto \frac{1}{\sqrt{T}}$$

둘째 계수의 95% 신뢰구간 = [0.402, 0.601] · 참값 0.5 포함

$$\hat{\phi}_2 \pm 1.96\,\mathrm{SE} = 0.502 \pm 1.96(0.051)$$



95% 신뢰구간 = 같은 절차를 반복하면 100번 중 약 95번 참값을 포함 (시뮬레이션 97/100)

MLE 대입 예측은 추정 오차를 무시한다

대입(plug-in) 예측분포: 추정값을 참값처럼 쓴다

$$x_{T+1} \mid x \;\sim\; N\left(\hat{\phi}_1 x_T + \hat{\phi}_2 x_{T-1},\; \hat{\sigma}^2\right)$$

1 추정값을 고정

계수와 잡음 크기를 하나의 값으로 정해 예측 공식에 넣는다.

2 빠진 불확실성

추정값도 표본마다 흔들린다(표준오차 0.05). 이 흔들림이 예측구간에 없다.

3 해결책

모수를 분포로 다루고 그 분포 전체로 예측한다 → 베이지안 방법.

데이터가 길면 무시해도 되지만, 짧으면 예측구간이 실제보다 좁아진다

PART 4

베이지안 추정

베이즈 정리 · 수축 · 사전분포 · MCMC · 사후분포

베이즈 정리는 사전 믿음을 데이터로 갱신하는 규칙이다

베이즈 정리

$$p(\theta \mid x) = \frac{p(x \mid \theta)\, p(\theta)}{p(x)} \propto p(x \mid \theta)\, p(\theta)$$

믿음 × 증거 → 새 믿음

사전분포	×	우도	∝	사후분포
$p(\theta)$		$p(x \mid \theta)$		$p(\theta \mid x)$
데이터 전 믿음		데이터의 증언		갱신된 믿음

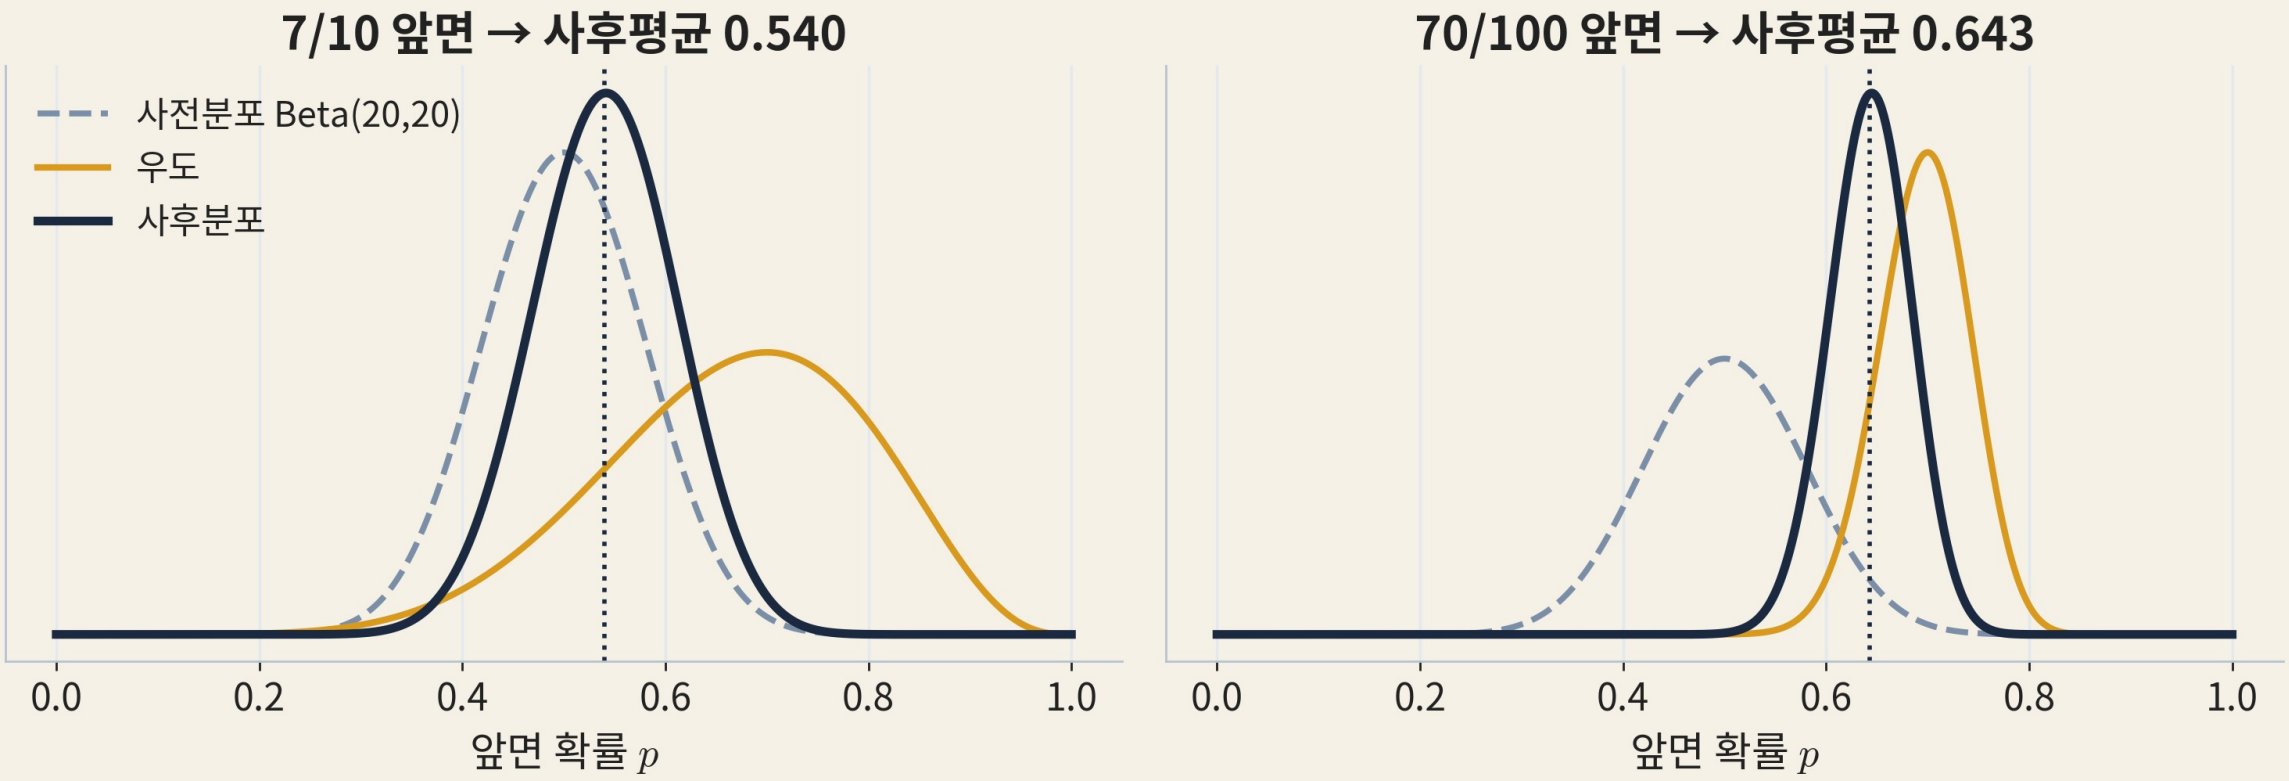
오늘의 사후분포 = 내일의 사전분포

빈도주의와 베이지안은 모수를 보는 관점이 다르다

	빈도주의 (MLE)	베이지안
모수	고정된 미지의 값	확률분포를 갖는 변수
결과	추정값 하나 + 표준오차	사후분포 전체
95% 구간 해석	같은 절차를 반복하면 95%가 참값 포함	모수가 이 구간에 있을 확률 95%
사전 정보	쓰지 않음	사전분포로 반영
계산	최적화 (미분 = 0)	적분 → MCMC 표본으로 근사

데이터가 충분하면 두 방법의 숫자는 비슷하다 — 다른 것은 해석과 예측의 폭이다

강한 사전분포는 적은 데이터를 0.5 쪽으로 끌어당긴다



데이터가 10배 늘면 사전분포의 영향이 줄고 사후평균이 표본비율 0.7에 다가간다

사후평균은 사전평균과 표본비율의 가중평균이다

베타 사전분포 + 동전 데이터 → 베타 사후분포

$$\mathrm{Beta}(a,b) + h \text{ 앞면 } / \, n \text{ 회} \;\Rightarrow\; \mathrm{Beta}(a+h,\; b+n-h)$$

사후평균 = 가중평균

$$E[p \mid x] = \frac{a+h}{a+b+n} = w \cdot \frac{a}{a+b} + (1-w) \cdot \frac{h}{n}, \quad w = \frac{a+b}{a+b+n}$$

앞면 7/10 · 사전 무게 0.80

$$\frac{20+7}{40+10} = 0.540$$

앞면 70/100 · 사전 무게 0.29

$$\frac{20+70}{40+100} = 0.643$$

데이터가 많을수록 사전 무게가 줄어든다 — 이것이 수축(shrinkage)의 원리다

AR(2)에는 넓은 사전분포를 두어 데이터가 말하게 한다

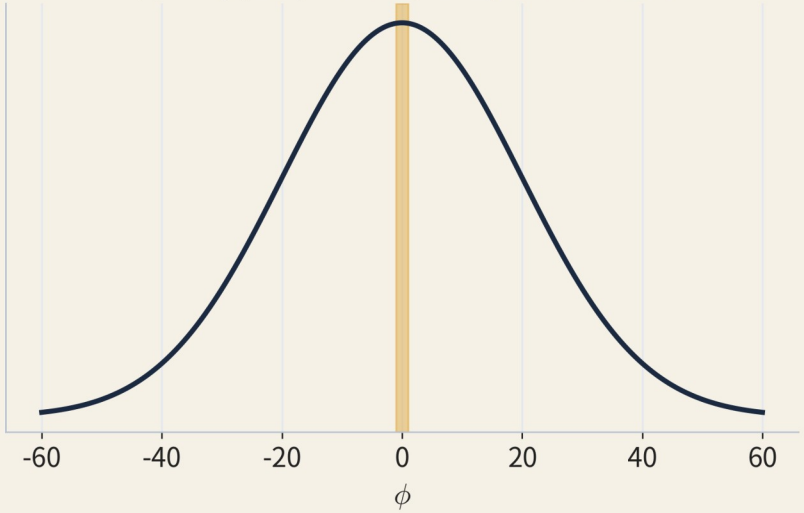
사전분포

$$\phi_1, \phi_2 \sim N(0,\ 20^2), \qquad \sigma \sim \mathrm{Exp}(1)$$

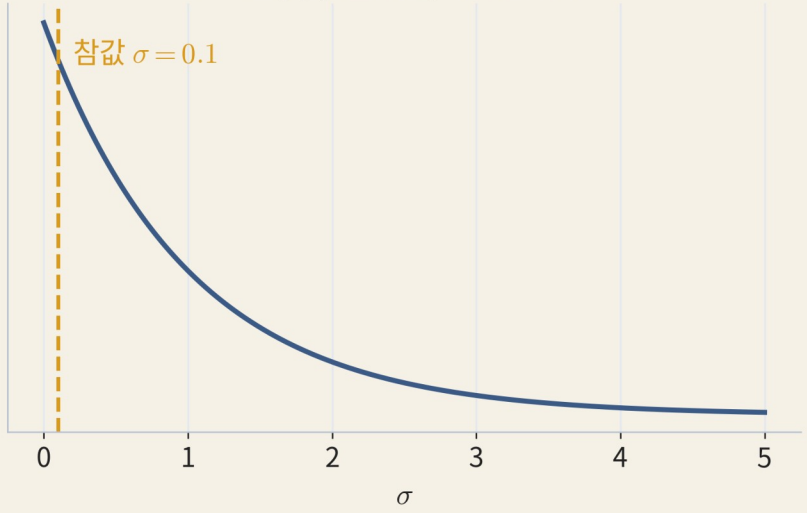
우도 (PART 3과 동일)

$$x_t \mid \phi, \sigma \ \sim \ N(\phi_1 x_{t-1} + \phi_2 x_{t-2},\ \sigma^2)$$

$\phi_i \sim N(0, 20^2)$: 금색 띠(−1~1)에서 거의 평평

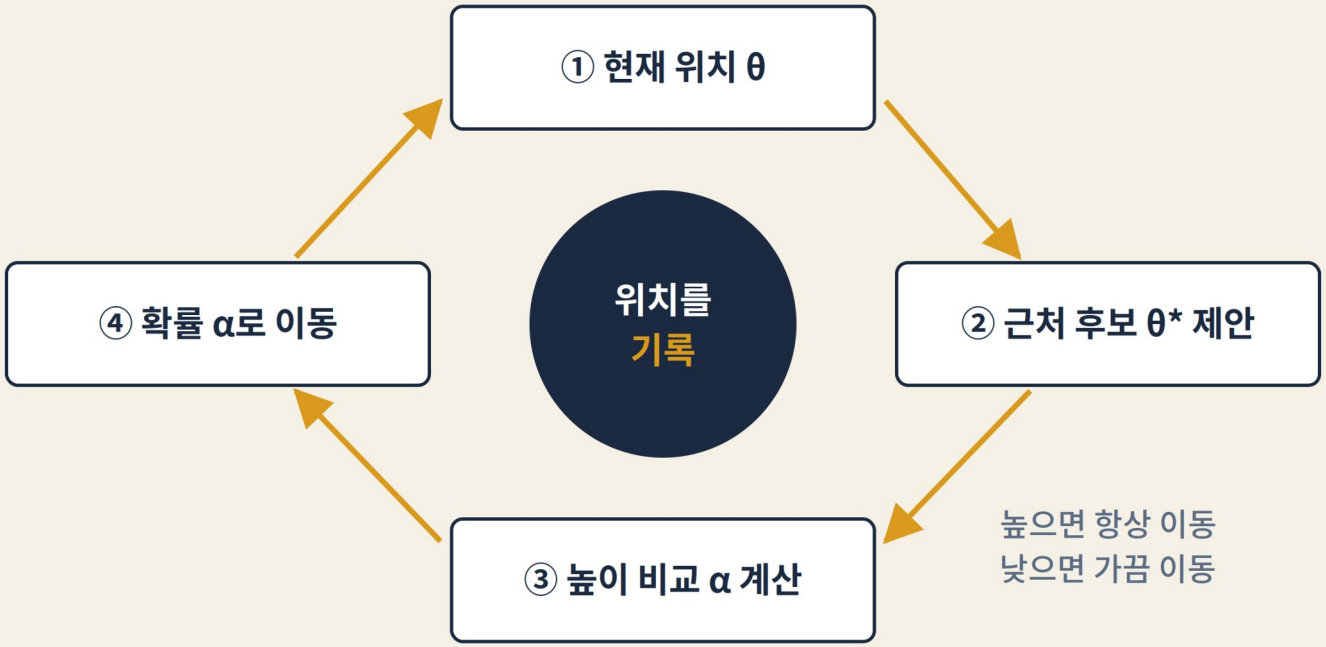


$\sigma \sim \mathrm{Exp}(1)$: 양수만, 작은 값에 무게



정상 영역(−1~1)에서 거의 평평한 사전분포 → 결과가 MLE와 거의 같아진다

사후분포는 적분이 어려워 MCMC 표본으로 근사한다

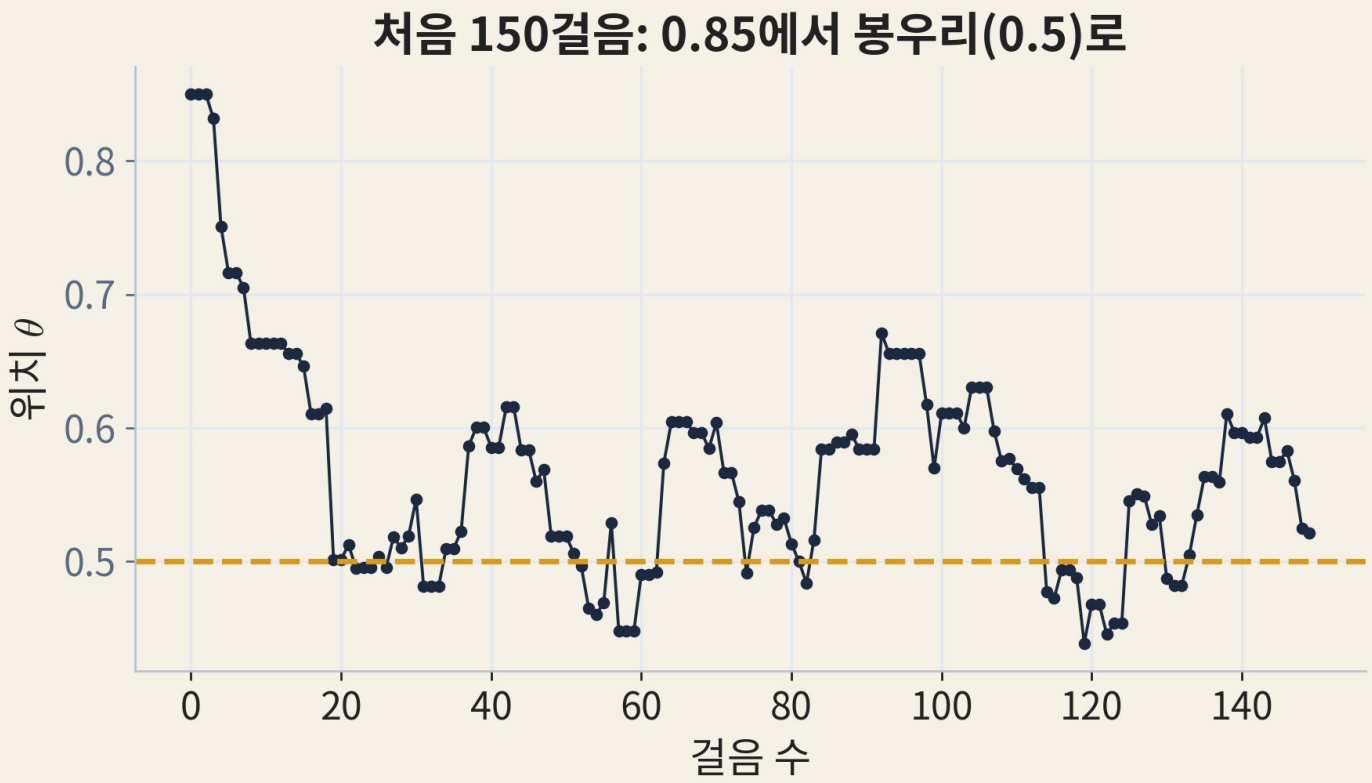


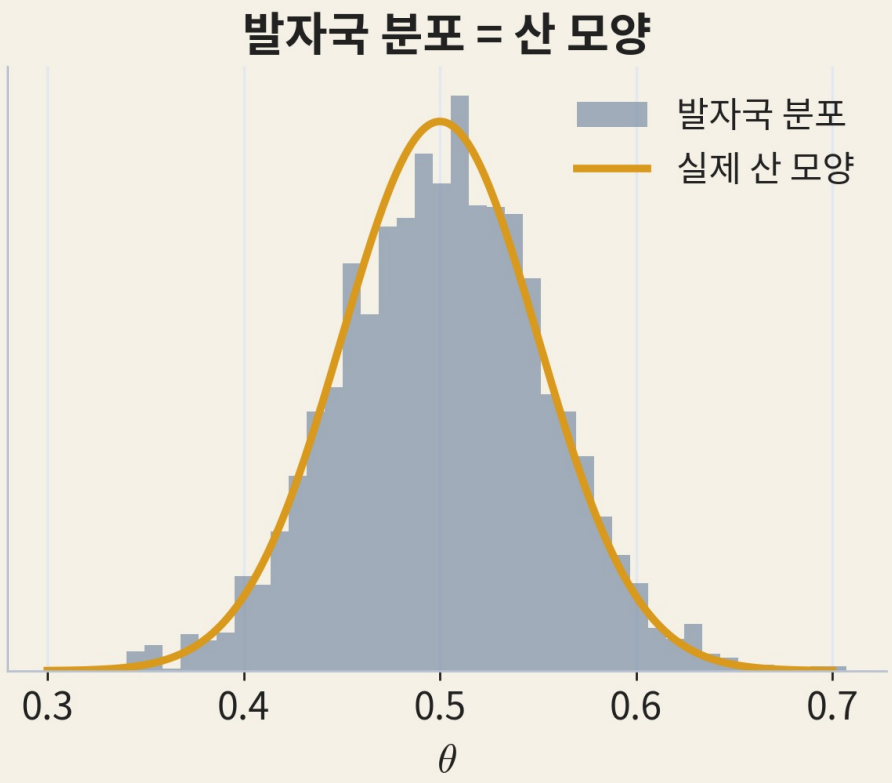
메트로폴리스 규칙

$$\alpha = \min\left(1, \frac{p(\theta^* \mid x)}{p(\theta \mid x)}\right)$$

- 베이즈 정리의 분모가 약분되어 계산할 필요가 없다
- 오래 걸으면 발자국 분포 = 사후분포
- PyMC는 개선판인 NUTS를 쓴다

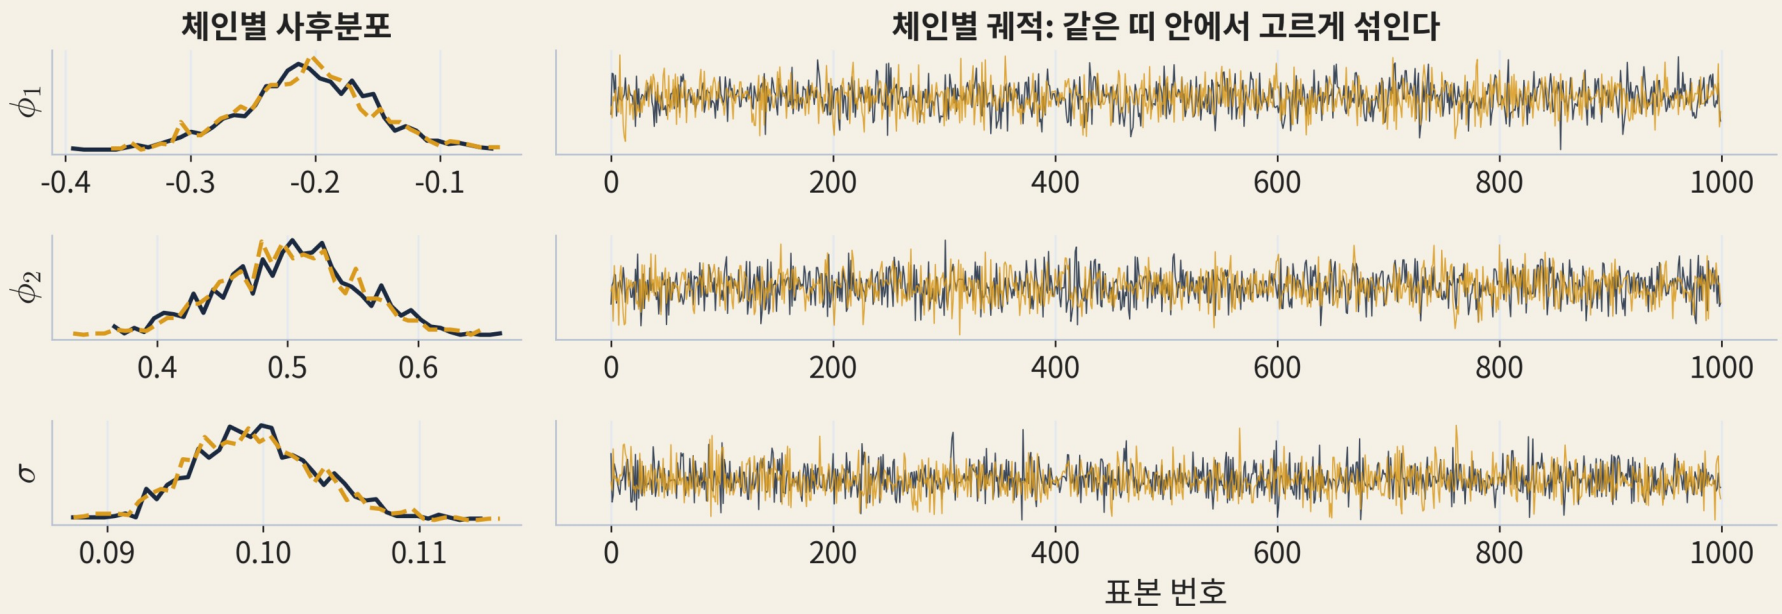
높은 곳에 오래 머문 발자국이 산 모양을 그린다





초반 발자국(번인)은 버리고 나머지를 사후 표본으로 쓴다

체인이 잘 섞였는지 R-hat과 ESS로 확인한다



1.00
R-hat: 세 모수 모두 (기준 1.01 이하)

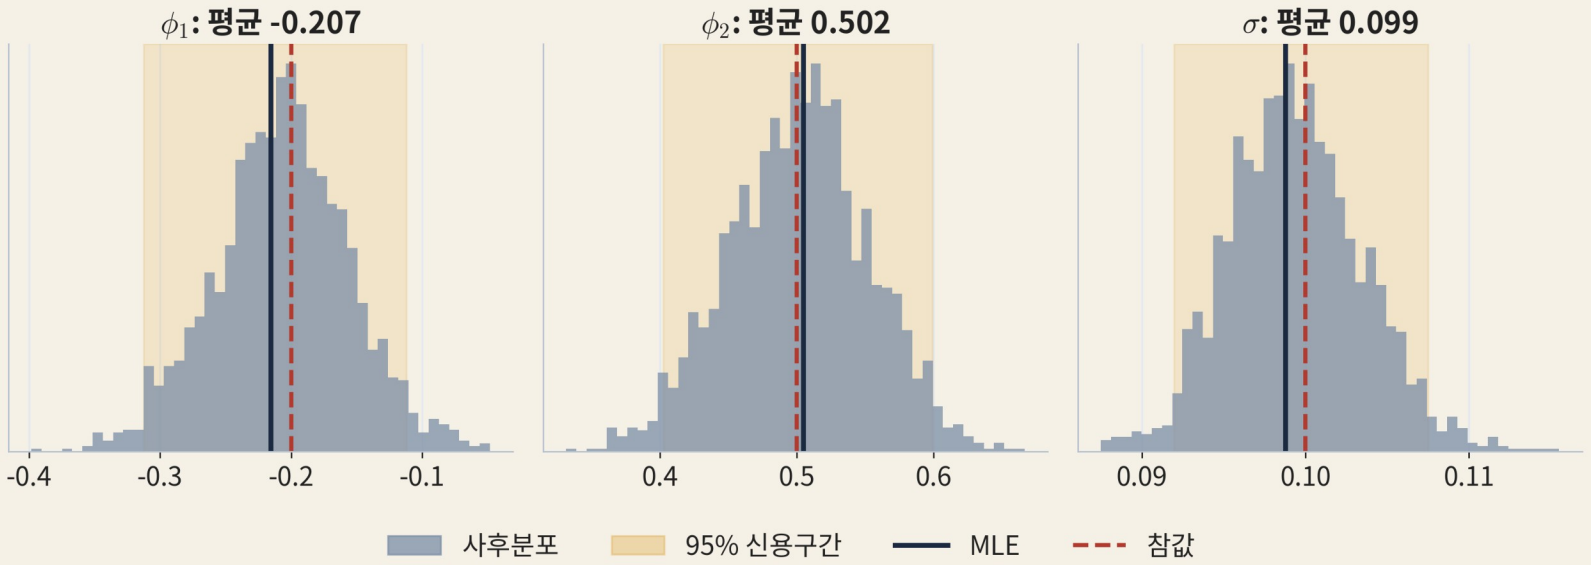
1,884
첫째 계수 유효표본수(ESS)

2,002
둘째 계수 유효표본수

2,892
잡음 표준편차 유효표본수

PyMC NUTS · 체인 2개 × 표본 1,000개 (튜닝 1,000)

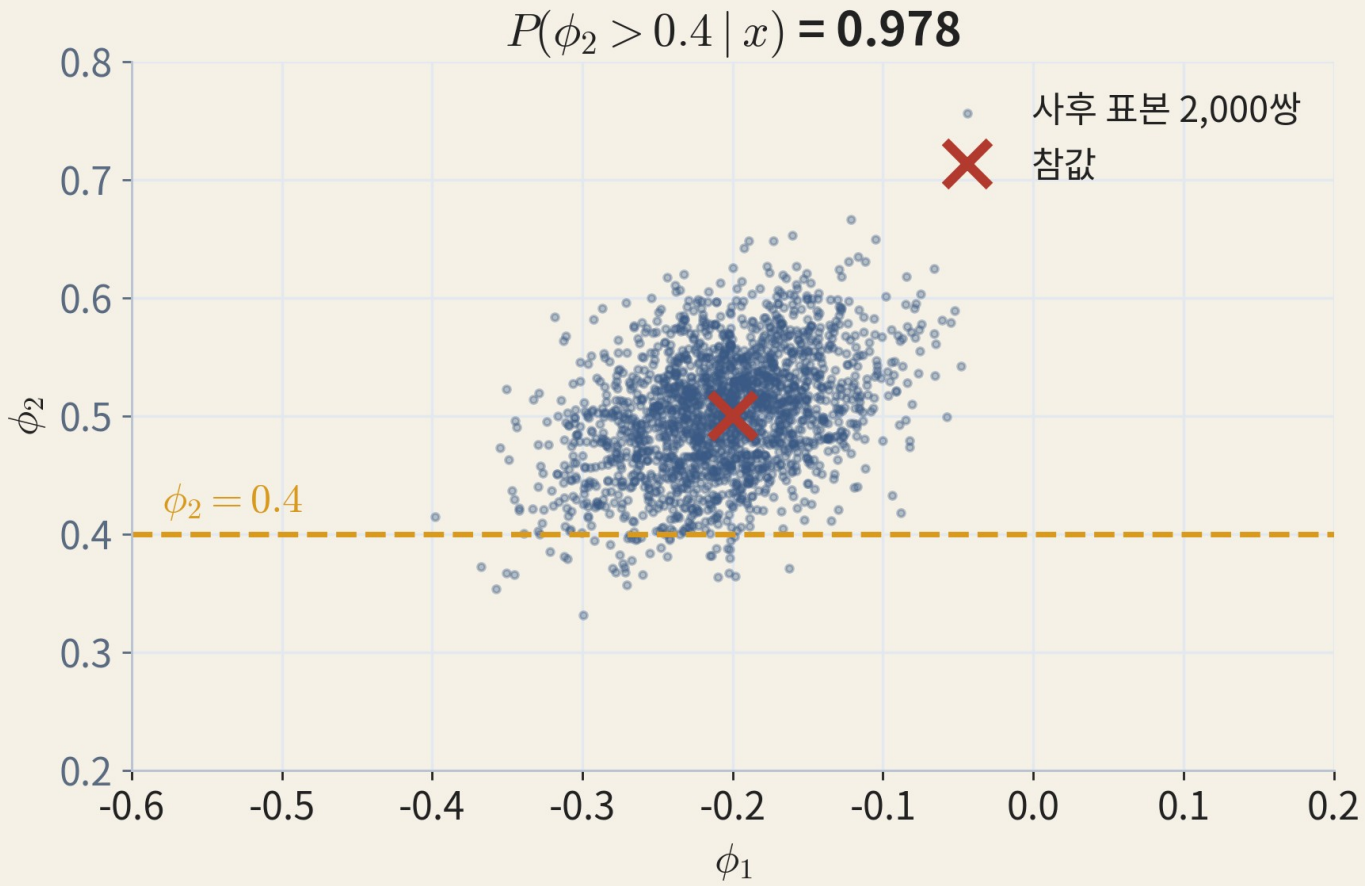
사후분포는 MLE와 같은 곳에 모이며 폭까지 알려 준다



	ϕ_1	ϕ_2	σ
사후평균 [95% 신용구간]	−0.207 [−0.313, −0.112]	0.502 [0.402, 0.599]	0.099 [0.092, 0.107]
정확 MLE	−0.215	0.505	0.0988

예제 데이터: AR(2) 계수 −0.2, 0.5, 잡음 표준편차 0.1, T = 300, seed 7 (시뮬레이션)

베이지안은 모수에 대한 확률 질문에 직접 답한다



사후 표본으로 바로 계산

$$P(\phi_2 > 0.4 \mid x) = 0.978$$

- 둘째 계수가 0.4를 넘을 확률 97.8%
- 첫째 계수가 음수일 확률 100%
- 신용구간은 "모수가 이 안에 있을 확률 95%"로 읽는다
- 표본 중 조건을 만족하는 비율을 세면 끝

PART 5

베이지안 예측과 적용

사후예측분포 · 분산 분해 · 짧은 데이터 · 민감도 · 미국 GDP

사후예측분포는 모든 모수 후보의 예측을 평균한다

사후예측분포

$$p(x_{T+h} \mid x) = \int p(x_{T+h} \mid \theta, x)\, p(\theta \mid x)\, d\theta$$

모수 불확실성 + 미래 충격을 함께 뽑는다



MLE 대입 예측은 1단계에서 추정값 하나만 쓴다

예측 분산의 97%는 미래 충격, 3%는 모수 불확실성이다

T+1 예측 분산 분해 (전체 분산 법칙)

$$\mathrm{Var}(x_{T+1} \mid x) = \underbrace{E[\sigma^2 \mid x]}_{\text{충격}} + \underbrace{\mathrm{Var}(\phi_1 x_T + \phi_2 x_{T-1} \mid x)}_{\text{모수 불확실성}}$$

$$0.009901 + 0.000271 = 0.010172$$

97.3%
미래 충격 몫

2.7%
모수 불확실성 몫

0.1006
T+1 예측 표준편차 (베이지안)

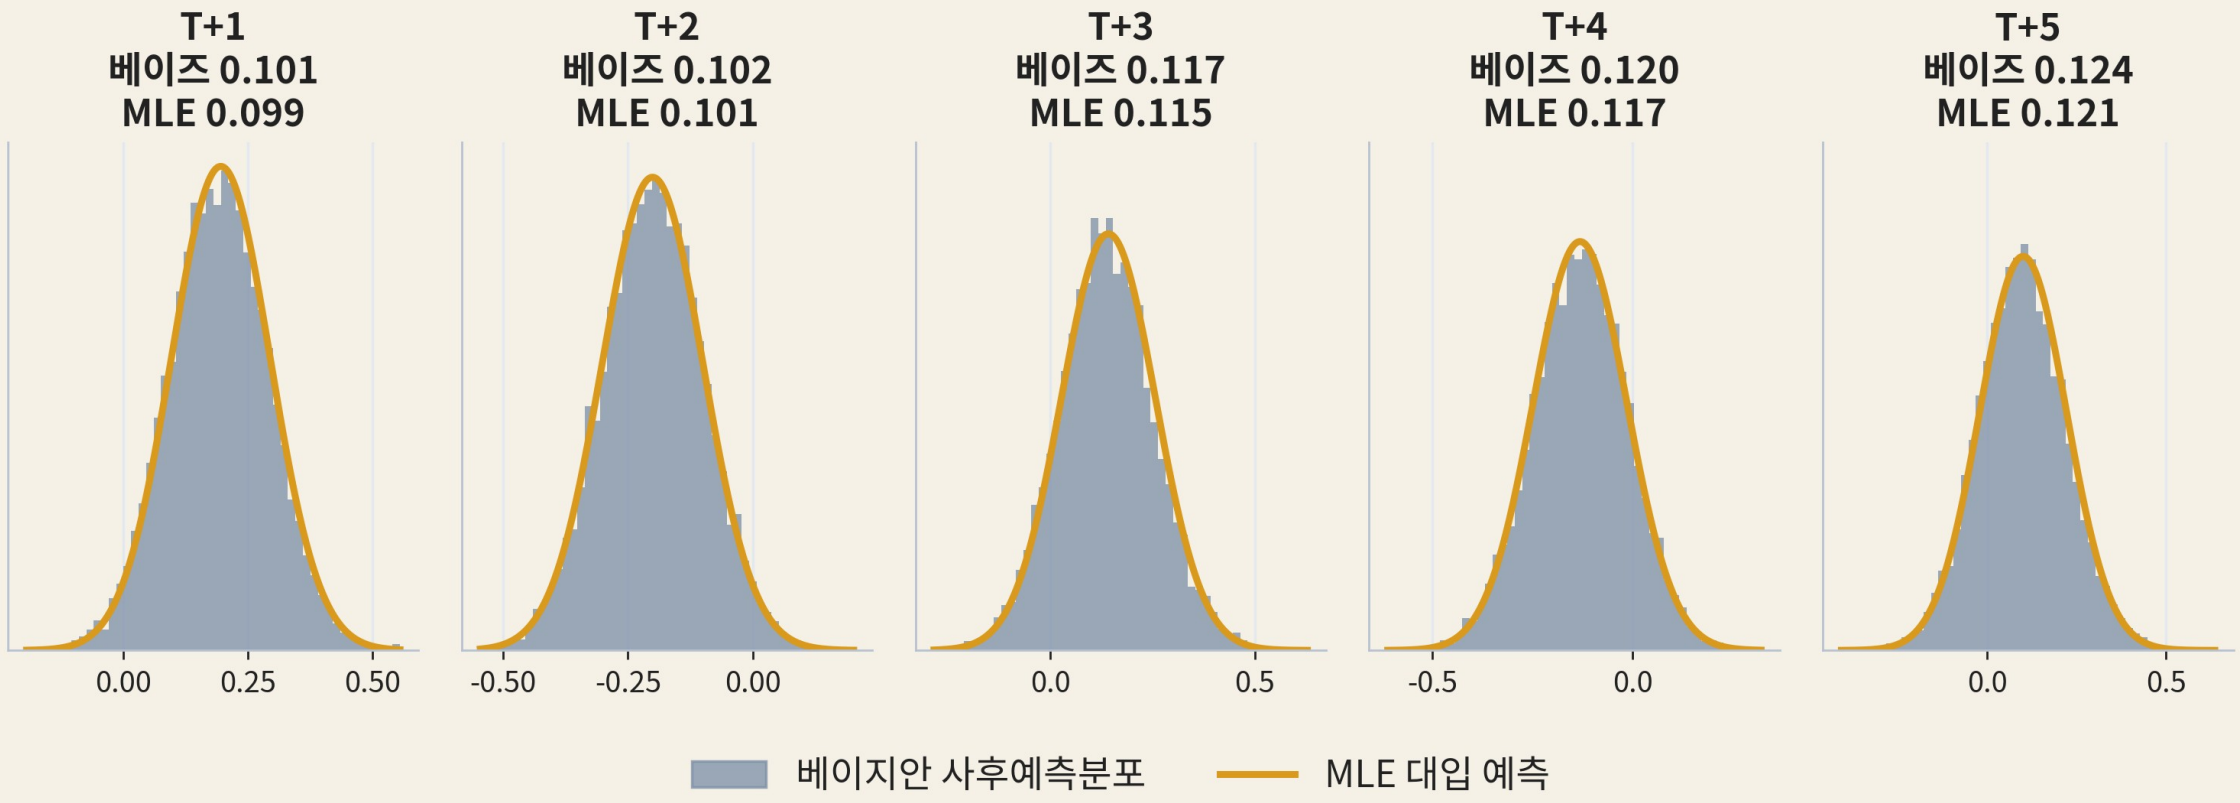
0.0988
T+1 예측 표준편차 (MLE)

모수 불확실성 몫은 데이터 길이 T에 반비례해 줄어든다

예제 데이터: AR(2) 계수 −0.2, 0.5, 잡음 표준편차 0.1, T = 300, seed 7 (시뮬레이션)

PART 5 · T = 300

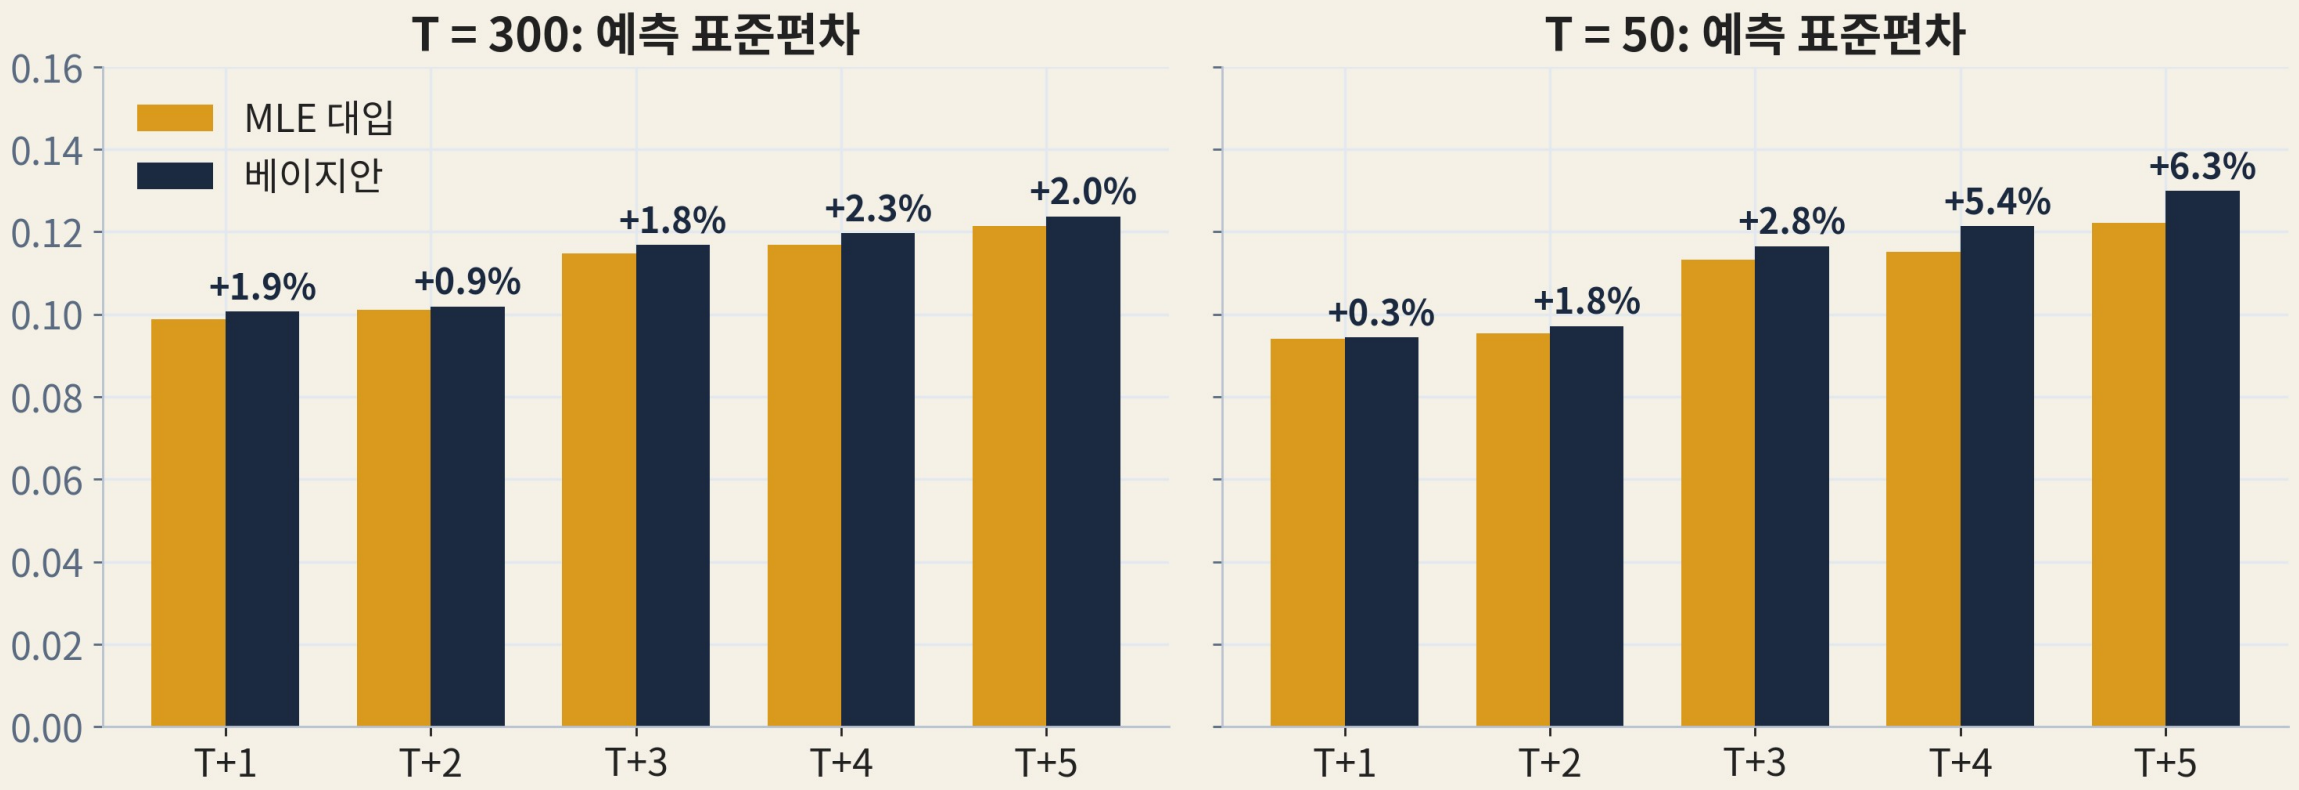
데이터가 길면 두 예측분포가 거의 겹친다



모수 불확실성이 작으면 베이지안 ≈ MLE — 표준편차 차이 1~2%

예제 데이터: AR(2) 계수 −0.2, 0.5, 잡음 표준편차 0.1, T = 300, seed 7 (시뮬레이션)

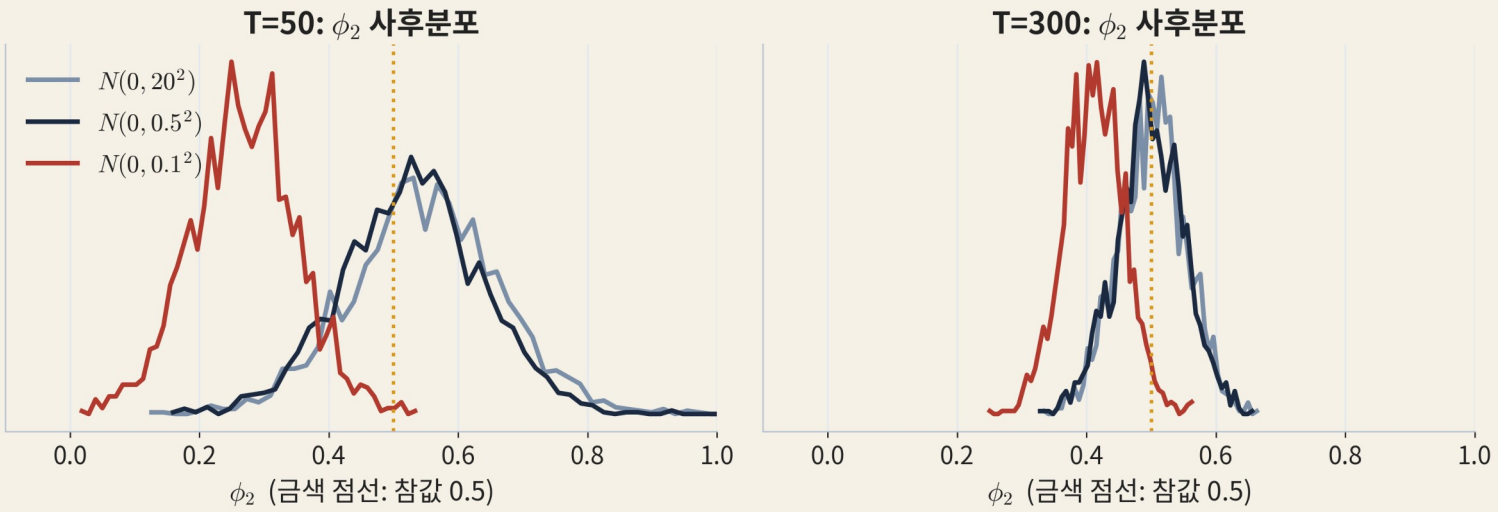
데이터가 짧을수록 먼 미래의 베이지안 구간이 더 넓다



T = 50: T+1 +0.3% → T+5 +6.4% · 먼 미래일수록 모수 오차가 누적된다

T = 50 데이터: 같은 모형, seed 16

사전분포의 영향은 데이터가 짧을 때 크다



사전 표준편차	T = 50	T = 300
20 (매우 넓게)	0.550	0.502
0.5 (보통)	0.528	0.498
0.1 (0 쪽으로)	**0.268**	**0.412**

표 값: 둘째 계수 사후평균 (참값 0.5)

짧은 데이터 (T = 50)

강한 사전분포가 0.55를 0.27까지 끌어내린다

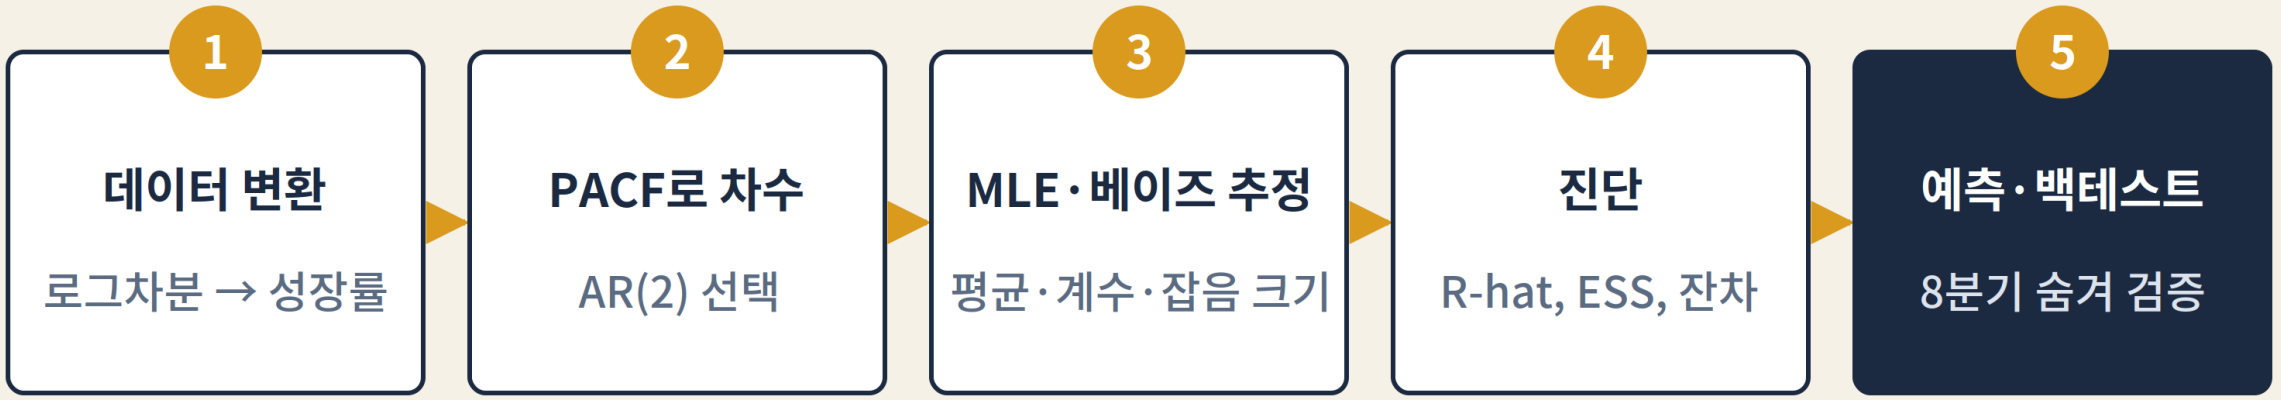
긴 데이터 (T = 300)

같은 사전분포에도 0.41 — 데이터가 사전분포를 이긴다

사전분포 선택은 결과를 바꿀 수 있다 — 민감도 분석으로 확인하고 함께 보고한다

미국 GDP 성장률을 같은 절차로 분석한다

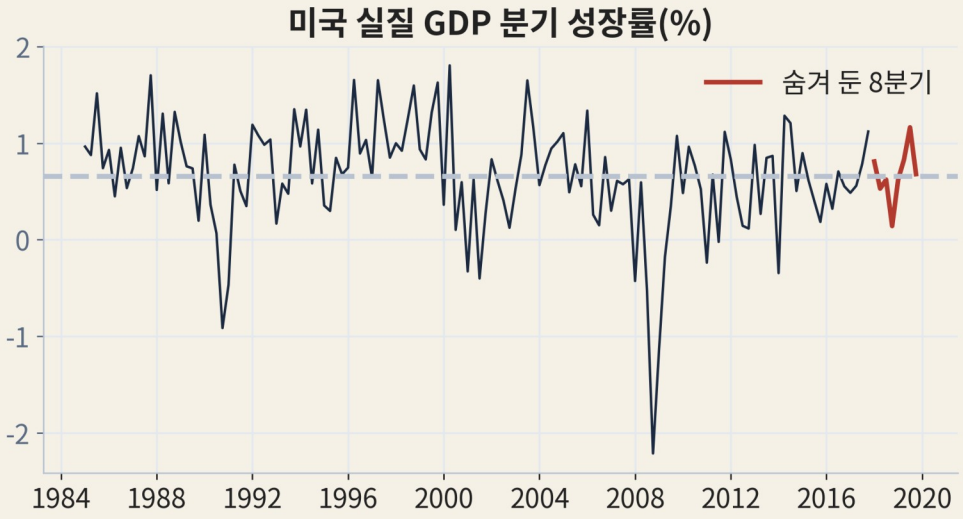
미국 실질 GDP (FRED: GDPC1), 1985–2017 추정

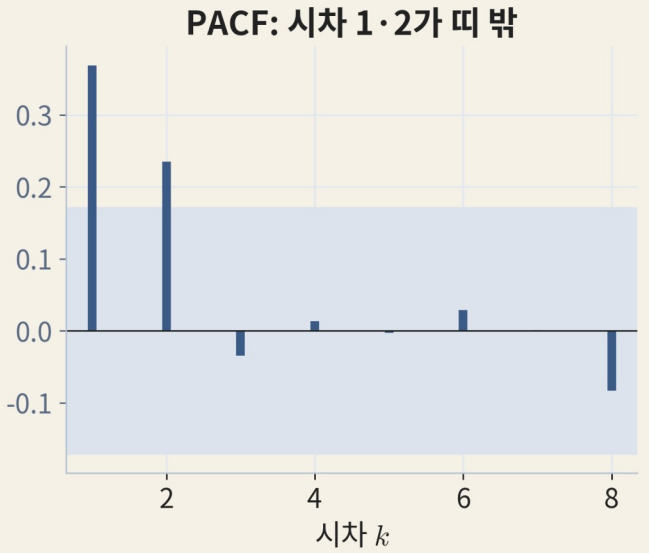


데이터는 FRED에서 직접 내려받는다

자료: FRED GDPC1 미국 실질 GDP, 로그차분 × 100 (분기 성장률, %)

성장률은 평균 0.66% 주위를 맴도는 AR(2)로 설명된다





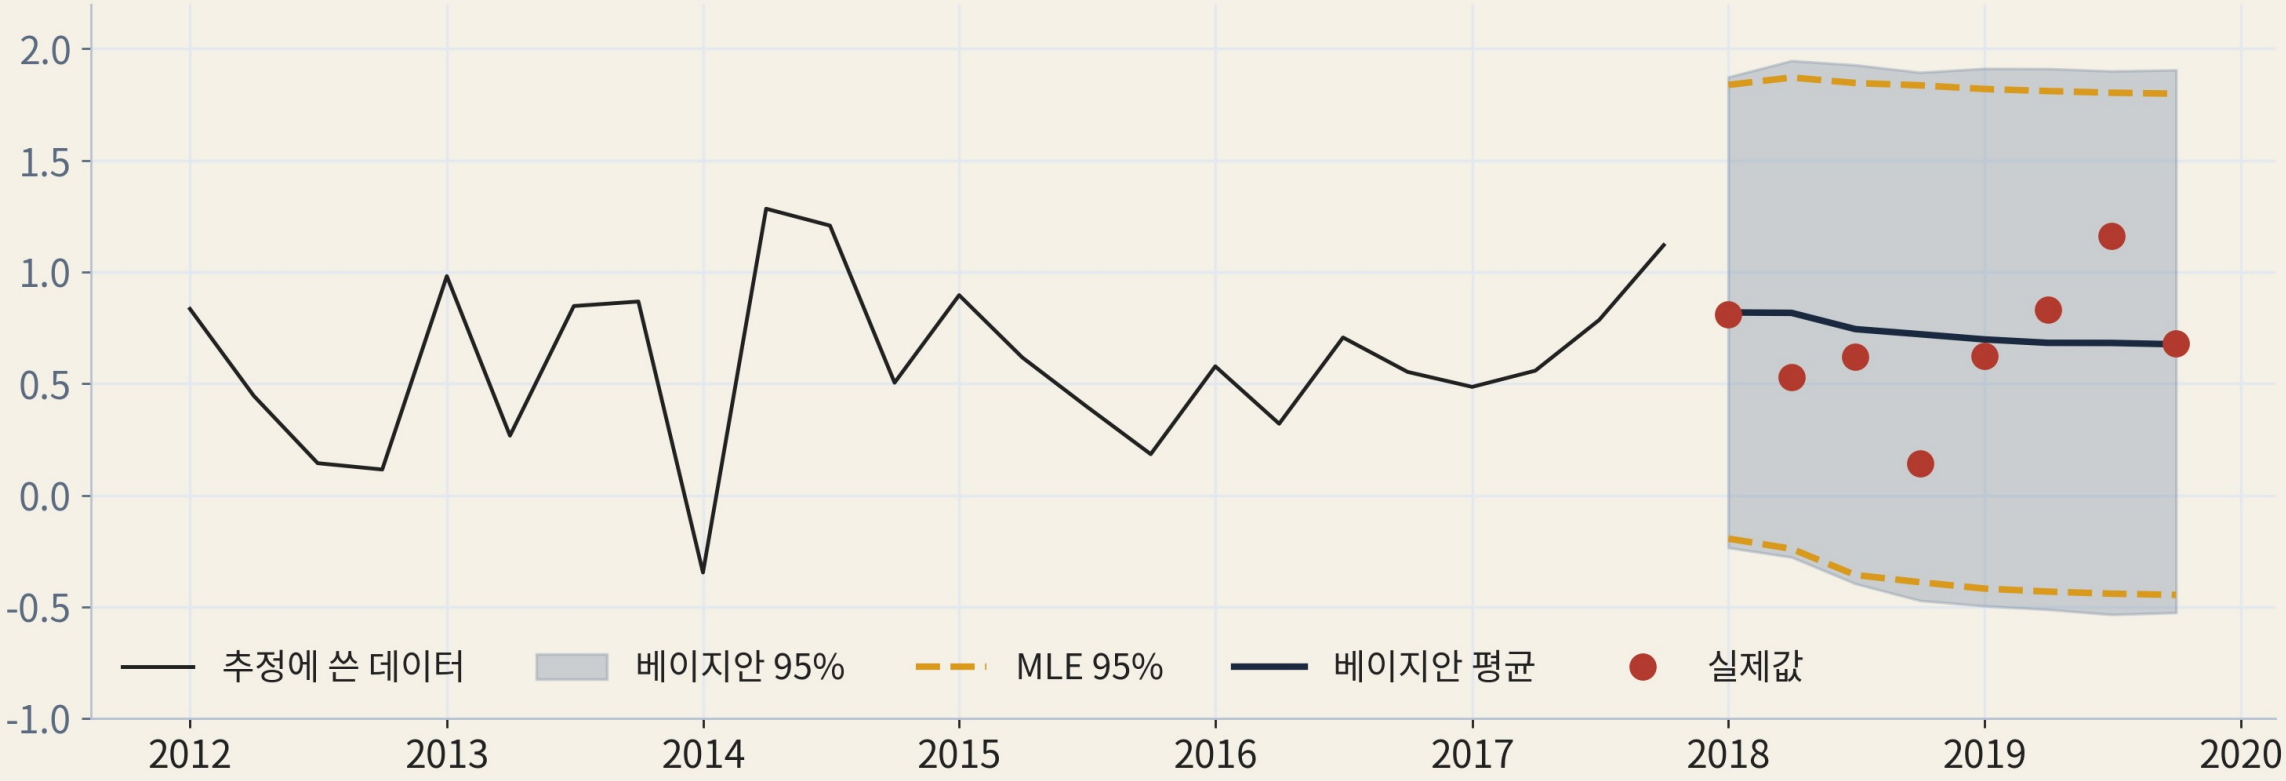
평균 m을 둔 AR(2)

$$y_t - m = \phi_1(y_{t-1} - m) + \phi_2(y_{t-2} - m) + \varepsilon_t$$

	m	ϕ_1	ϕ_2	σ
베이지안	0.656	0.292	0.248	0.532
MLE	0.667	0.281	0.232	0.519

자료: FRED GDPC1 미국 실질 GDP, 로그차분 × 100 (분기 성장률, %)

숨겨 둔 2018–2019년 8분기가 모두 95% 구간 안에 들어온다



132분기로 충분히 길어 두 방법의 구간이 거의 같다 — 8/8 적중

자료: FRED GDPC1 미국 실질 GDP, 로그차분 × 100 (분기 성장률, %)

종합

MLE와 베이지안은 같은 모형을 다른 방식으로 푼다

	최대우도 (MLE)	베이지안
추정 결과	점 추정값 + 표준오차	사후분포 (MCMC 표본)
예제 둘째 계수	0.505 (표준오차 0.051)	0.502 (95% 신용구간 0.40–0.60)
예측 방법	추정값을 대입	사후예측분포 (모수 불확실성 포함)
T = 300 예측 폭	기준	T+1에서 +1.8%
T = 50 예측 폭	기준	T+1 +0.3% → T+5 +6.4%
강점	빠르고 단순하다	확률 해석 · 사전 정보 · 짧은 데이터

긴 데이터에서는 둘 다 좋다 — 짧은 데이터와 확률 질문에서 베이지안이 빛난다

모형 · 추정 · 예측을 불확실성과 함께 다룬다

1 모형

정상성 삼각형 안의 AR(p). 자기상관은 율-워커, 차수는 PACF로 정한다.

2 추정

MLE는 OLS와 같다. 베이지안은 사전분포 × 우도를 MCMC로 근사한다.

3 예측

사후예측분포 = 미래 충격 + 모수 불확실성. 짧은 데이터일수록 차이가 커진다.

"얼마나 확실한가"까지 답하는 것이 베이지안 시계열의 핵심이다

다음 단계: 계절 AR, ARMA, 확률적 변동성 모형으로 확장